

Universidade Federal do Rio de Janeiro

Escola Politécnica

Departamento de Eletrônica e de Computação

**Estimativa Neural de Energia em Espaço Morto de um
Calorímetro de Altas Energias**

Autor:

Natanael Nunes de Moura Junior

Orientador:

Prof. José Manoel de Seixas, D. Sc.

Examinador:

Prof. Miriam Mendes Gandelman, D. Sc.

Examinador:

Prof. Joarez Bastos Monteiro, D. Sc.

Examinador:

Prof. Luis Pereira Calôba, D. Ing.

DEL

Agosto de 2011

AGRADECIMENTO

Primeiramente a Deus, que mesmo com toda a minha infidelidade sempre esteve ao meu lado.

Aos meus pais, Natanael e Neidimar, pelos conselhos, pelas orientações e acima de tudo pela paciência e carinho comigo.

Ao meu orientador, José Manoel de Seixas que foi um orientador dedicado, um mestre solícito e na maioria do tempo um grande amigo.

Aos meus amigos de faculdade, que ouviram pacientemente as minhas queixas e minhas frustrações.

Aos meus amigos do Laboratório de Processamento de Sinais, que sempre sanaram minhas dúvidas de forma formidável.

A todos os meus professores, que além de informações, me ensinaram sobre respeito e dignidade.

RESUMO

Experimentos com colisores partículas visam aprofundar nossos conhecimentos sobre a matéria e identificar processos complexos previstos teoricamente. Para isso, uma medida importante é a energia de partículas provenientes da colisão e esta medida é realizada com calorímetros.

Calorímetros estimam a energia de partículas por absorção total. Os perfis de deposição de energia também permite, a identificação de partículas de maneira eficiente, o que torna essencial a presença de calorímetros nos experimentos com colisores. O sistema de calorimetria é, tipicamente, altamente segmentado (centenas de milhares de canais de leitura) e compreende duas seções: uma dedicada às partículas que interagem eletromagneticamente e outra responsável por estimar a energia de interação hadrônica. A parte eletromagnética é normalmente montada dentro da parte hadrônica.

No CERN (Centro Europeu de Pesquisa Nuclear), o Grande Colisionador de Hádrons (LHC, em inglês) começou a colidir feixes de prótons no ano passado. LHC é a maior máquina já construída pelo homem e é projetado para atingir 14 TeV de energia com colisões ocorrendo em um período de 25 nanossegundos. A fim de medir os subprodutos resultantes das colisões, detectores de partículas são acoplados em torno dos pontos de colisão do LHC.

ATLAS é o maior detector do LHC e tem dois calorímetros principais. O LAr é o primeiro componente do sistema de calorimetria e é responsável pela absorção da energia de partículas eletromagnéticas, enquanto TileCal é o principal calorímetro hadrônica.

O calorímetro LAr tem o seu sistema de leitura imerso em Argônio líquido, a fim de reduzir o ruído eletrônico e obter uma resolução de alta energia. Isso requer o uso de câmaras criostáticas. Como o LAr está dentro do TileCal, todos os cabos de alimentação e de sinal atravessam o interior do TileCal. Estes cabos combinados com as câmaras criostáticas formam as regiões de materiais mortos, para as quais não há leitura eletrônica.

As regiões materiais mortos produzem um aumento da não-linearidade na resposta do calorímetro, que tem de ser compensado. No presente trabalho, nós

vamos analisar a resposta de um estimador neural de energia para diferentes tipos de entrada e diferentes níveis de agrupamento de variáveis.

Palavras-Chave: CERN, ATLAS, física, calorimetria, redes neurais.

ABSTRACT

Modern particle collider experiments aim at probing deeper into matter and identify complex processes that have been foreseen theoretically. For this, an important measure is the energy of incoming particles, which is performed by calorimeters.

Calorimeters estimate the energy of particles by total absorption. The energy deposition profiles also allow very efficient particle identification, which makes calorimeters essential for modern collider experiments. The calorimeter system is typically highly-segmented (hundred of thousands of readout channels) and comprises two sections: one dedicated to particles that interact electromagnetically and the other responsible for estimating the energy of hadronic interactions. The electromagnetic part is usually inside the hadronic one.

At CERN (European Centre for Nuclear Research), the Large Hadron Collider (LHC) started colliding bunches of protons last year. LHC is the largest collider machine ever built and is designed for 14 TeV collisions occurring at a 25 nanosecond period. In order to measure the subproducts resulting from collisions, particle detectors are placed around the LHC collision points.

ATLAS is the largest LHC detector and has two main calorimeters. The LAr is the first component of the calorimeter system and it is responsible for absorbing the energy of electromagnetic particles, while TileCal is the main hadronic calorimeter.

The LAr calorimeter has its readout system immersed in liquid Argon, in order to reduce electronic noise and achieve high energy resolution. This requires the use of cryostat chambers. As the LAr is inside the TileCal, all power and signal cables are forced to cross the TileCal structure. These cables combined with the cryostat chambers form the regions of dead materials, for which there is no electronic readout.

The dead material regions produce an increase in the nonlinearity of the calorimeter response, which has to be compensated for. In the present work, we evaluate the performance of the neural estimation when we have different kinds of input and when calorimeter information near this region is grouped together at different levels of granularity.

Key-words: CERN, ATLAS, physics, calorimetry, neural network.

SIGLAS

UFRJ - Universidade Federal do Rio de Janeiro.

LHC - Large Hadron Collider.

CERN - European Organization for Nuclear Research.

ATLAS - A Toroidal LHC ApparatuS.

TileCal - Tile Calorimeter.

LAr - Liquid Argon Calorimeter.

CMS - Compact Muon Solenoid.

LHCb - Large Hadron Collider beauty.

ALICE - A Large Ion Collider Experiment.

SCT - SemiConductor Tracker.

TRT - Transition Radiation Tracker.

ATHENA - ATLAS Framework.

ROOT - CERN's analysis environment.

CTB2004 - Combined Test Beam 2004.

MDS - Monitored Drift Tube.

RPC - Resistive Plate Chambers.

CSC - Cathode Strip Chambers.

PMT - Photo Multiplier Tube.

EBA - Extended Barrel A.

EBC - Extended Barrel C.

WLS - Wavelength Shifting Fibers.

ROD - Read-Out Driver.

OR - Optical Receiver.

PU - Processing Unit.

TTC - Timing, Trigger and Control.

MLP - Multi-Layer Perceptron.

BFGS - Broyden Fletcher Goldfarb Shanno method.

Sumário

1	Introdução	1
1.1	Tema	1
1.2	Justificativa	2
1.3	Objetivos	3
1.4	Organização do Texto	3
2	Ambiente de Trabalho	4
2.1	CERN e o LHC	6
2.2	ATLAS	6
2.2.1	Sistema de Coordenadas do ATLAS	7
2.2.2	Inner Detector, o detector de traços	8
2.2.3	Muon System	10
3	Calorimetria de Altas Energias	12
3.1	Tipos de Fenômenos de Detecção	12
3.1.1	Cintilação	12
3.1.2	Radiação de Cherenkov	13
3.1.3	Ionização	13
3.1.4	Bremsstrahlung	15
3.2	Tipos de Partículas	15
3.3	Tipos de Calorímetros	16
3.4	Parâmetros de Calorimetria	17
3.4.1	Resolução em Energia	17
3.4.2	Alcance em Posição	18
3.4.3	Granularidade	19

3.4.4	Efeitos da Não-Compensação	19
3.4.5	Tipos de Células de Leitura	19
3.4.6	Calibração de um Calorímetro	20
3.5	Liquid Argon, o calorímetro eletromagnético do ATLAS	22
3.6	TileCal, o calorímetro hadrônico do ATLAS	24
3.6.1	Cadeia de Leitura do TileCal	25
3.6.2	Regiões sem leitura	28
4	Estimador Neural de Energia para Regiões com Materiais sem Leitura	31
4.1	Modelos Anteriores	32
4.2	Estimador Neural de Energia	35
4.2.1	Dados utilizados	35
4.2.2	Entradas e saídas utilizadas	37
4.2.3	Treinamento e Camadas Escondidas	39
4.3	Figuras de Mérito	40
4.4	Resultados	42
4.4.1	Redes Neurais com uma camada escondida	42
4.4.2	Redes Neurais com duas camadas escondidas	51
5	Conclusões	57
	Bibliografia	59

Lista de Figuras

2.1	Tabela com as forças do modelo padrão.	5
2.2	Visão Aérea do CERN.	6
2.3	Detector de Partículas ATLAS.	7
2.4	Sistema de Coordenadas do ATLAS.	8
2.5	Visão Geral do Inner Detector.	9
2.6	Visão Geral do Muon System.	10
2.7	Distribuição das câmaras do Muon System.	11
3.1	Partícula desenvolvendo uma cintilação.	13
3.2	Partícula emitindo radiação de Cherenkov.	14
3.3	Partícula desenvolvendo uma ionização.	15
3.4	Partícula emitindo raio de bremsstrahlung.	16
3.5	Tubo foto-multiplicador em corte.	21
3.6	Visão Geral do Calorímetro Eletromagnético do ATLAS.	22
3.7	Células do LAr	24
3.8	Visão Geral do Calorímetro Hadrônico do ATLAS.	24
3.9	Módulo do TileCal.	26
3.10	Componentes do Calorímetro Hadrônico do ATLAS.	26
3.11	Vista longitudinal do ATLAS sem o TileCal	30
3.12	Vista longitudinal do ATLAS com o TileCal	30
4.1	Energia depositada na região sem leitura estimada com o modelo de referência para diferentes energias.	33
4.2	Valores da constante de calibração c_{dm} para diferentes energias. . . .	33
4.3	Configuração básica do TestBeam.	36
4.4	Energia normalizada na última camada do LAr	37

4.5	Energia normalizada na primeira camada do Tile	38
4.6	Energias depositadas em camadas do sistema de calorimetria.	38
4.7	Energia simulada como alvo para a rede neural com feixe de 100GeV	39
4.8	Exemplo de resultado de uma rede neural e um feixe de 100GeV.	41
4.9	Ganho absoluto para um estimador com 2 entradas, diferentes energias e diferentes topologias.	44
4.10	Ganho relativo para um estimador com 2 entradas, diferentes energias e diferentes topologias.	45
4.11	Distribuição espacial de Energia na última camada do LAr	45
4.12	Distribuição espacial de Energia na primeira camada do TileCal	46
4.13	Ganho absoluto para um estimador com 4 entradas, diferentes energias e diferentes topologias.	47
4.14	Ganho relativo para um estimador com 4 entradas, diferentes energias e diferentes topologias.	48

Lista de Tabelas

4.1	Resumo das topologias testadas pela colaboração CERN/ATLAS com suas especificações.	35
4.2	Ganhos para os experimentos com redes neurais na estimativa da energia na região sem leitura, realizados anteriormente pela colaboração CERN/ATLAS	42
4.3	Ganhos para duas entradas utilizando o algoritmo Steepest Descent. .	42
4.4	Ganhos para duas entradas utilizando o algoritmo BFGS.	43
4.5	Desempenho para quatro entradas e método de treinamento Steepest Descent.	46
4.6	Ganhos para quatro entradas e método de treinamento BFGS.	47
4.7	Ganhos para dez entradas e método de treinamento Steepest Descent.	48
4.8	Ganhos para dez entradas e método de treinamento BFGS.	49
4.9	Ganhos para seis entradas e método de treinamento Steepest Descent.	50
4.10	Ganhos para seis entradas e método de treinamento BFGS.	50
4.11	Ganhos para redes neurais com duas entradas e duas camadas escondidas e utilizando o algoritmo Steepest Descent.	51
4.12	Ganhos para redes neurais com duas entradas e duas camadas escondidas e utilizando o algoritmo BFGS.	52
4.13	Ganhos para redes neurais com quatro entradas e duas camadas escondidas e utilizando o algoritmo Steepest Descent.	53
4.14	Ganhos para redes neurais com quatro entradas e duas camadas escondidas e utilizando o algoritmo BFGS.	54
4.15	Ganhos para redes neurais com dez entradas e duas camadas escondidas e utilizando o algoritmo Steepest Descent.	54

4.16	Ganhos para redes neurais com dez entradas e duas camadas escondidas e utilizando o algoritmo BFGS.	55
4.17	Ganhos para redes neurais com seis entradas e duas camadas escondidas e utilizando o algoritmo Steepest Descent.	55
4.18	Ganhos para redes neurais com seis entradas e duas camadas escondidas e utilizando o algoritmo BFGS.	56

Capítulo 1

Introdução

Este capítulo tem por objetivo fornecer a introdução do tema do projeto final, bem como a justificativa do trabalho, seus objetivos. Ao final do capítulo temos a descrição da organização do texto.

1.1 Tema

Em um sistema de instrumentação eletrônica, a medição feita pelos sensores ou transdutores, a transmissão dos sinais obtidos e o armazenamento e/ou análise dos mesmos possuem papel fundamental. Nos dias atuais, existe uma grande necessidade de sistemas que forneçam medidas mais rápidas e com maior precisão.

Em sistemas que possuem uma grande quantidade de canais de leitura, a velocidade de processamento da informação é muito importante, bem como a relação entre o sinal de interesse proveniente do sistema e o ruído gerado pelo sistema de aquisição.

Outro fator, que deve ser ponderado, no que concerne sistemas de instrumentação, é a linearidade associada à técnica de medida. As não-linearidades podem também ser influenciadas pela forma como o projeto foi implementado e diversos algoritmos buscam compensar seus efeitos.

No contexto de física experimental de altas energias, sistemas de instrumentação são desenvolvidos para um experimento específico, o que faz com que laboratórios de física experimental se tornem, também, centros de desenvolvimento em sistemas de instrumentação.

O objeto de estudo deste trabalho é um sistema de calorimetria, composto, principalmente, por dois calorímetros, e que está acoplado ao detector ATLAS, pertencente ao CERN. O modelo computacional está voltado para o processo de reconstrução de energia e a redução das não-linearidades na resposta do calorímetro.

O tema do trabalho é a utilização de redes neurais para a estimação da energia depositada em uma região sem leitura de um calorímetro hadrônico. Estimadores Neurais são baseados na capacidade de generalização que uma rede neural possui, sendo assim capazes de estimar com precisão as mais variadas faixas de energia.

1.2 Justificativa

Na estimação de uma determinada quantidade, uma característica básica deve ser considerada: a resolução da medida. No caso dos calorímetros, equipamentos desenvolvidos para medição de energia de partículas de elevada energia por meio de absorção total, o problema se torna ainda mais complexo, pois os mesmos atuam em uma ampla faixa dinâmica (de MeV a TeV), possuem não-linearidades inerentes a um projeto prático e precisam atingir uma resolução elevada, para que seja possível a medida de energia nos experimentos com colisão de partículas.

A calorimetria do detector ATLAS é composta pelo TileCal(calorímetro baseado em telhas cintilantes) e pelos detectores de Argônio Líquido(LAr). Como a parte central do LAr é envolvido pelo TileCal, toda alimentação de seus equipamentos passa por dentro do TileCal até alcançar detector. Assim sendo, cria-se um espaço morto no TileCal e, por consequência, perde-se uma parte da energia a ser absorvida. A energia “perdida” nesta parte do detector deve ser estimada para uma posterior compensação offline durante a análise dos dados provenientes do sistema de calorimetria do ATLAS.

As redes neurais artificiais foram aplicadas como método para redução das não-linearidades na leitura do TileCal, o que nos motiva a utilizar esta técnica para uma análise das respostas da região sem leitura do TileCal.

1.3 Objetivos

Atualmente, a estimação de energia na região sem leitura é feita através da média geométrica de camadas específicas do TileCal e do barril do LAr, que relaciona, através de uma constante de calibração, a energia depositada nesta área. Este trabalho tem como objetivo melhorar a estimação de energia na área sem leitura do calorímetro, para que assim possamos diminuir o erro final na medida da energia depositada no sistema de calorimetria, e por conseguinte melhorarmos a resposta total do detector ATLAS.

1.4 Organização do Texto

Veremos o ambiente onde este trabalho está inserido, a certificação do sistema eletrônico e comissionamento e, por fim, o estimador neural para materiais mortos.

No capítulo 2, será feita uma introdução ao ambiente de Física de Altas Energias. Um dos detectores pertencente ao CERN, o ATLAS, será apresentado bem como as suas principais características. Ainda no capítulo 2, será apresentado o calorímetro hadrônico do ATLAS, o Tilecal, fonte dos dados usados nesse trabalho. No capítulo 3, veremos as configurações das redes neurais utilizadas neste trabalho. No capítulo 4, veremos os resultados obtidos com a pesquisa realizada e as conclusões obtidas com os mesmos.

Capítulo 2

Ambiente de Trabalho

A física experimental de altas energias é a área da física que destina-se ao estudo das propriedades fundamentais da matéria, bem como seus componentes e as interações realizadas pelos mesmos. Sua origem data da Grécia Antiga com a definição do átomo por Demócrito, que posteriormente seria contestada por pesquisadores como Dalton e Faraday[1].

Atualmente, a teoria mais aceita na comunidade científica é o Modelo Padrão[1]. Esse modelo descreve com qualidade as interações entre as partículas mais fundamentais. Neste modelo, existem duas classes básicas: os férmions e os bósons. Todas as partículas elementares, ou seja, as que originam outras, estão classificadas dentro desses dois grupos principais.

Os férmions são partículas que obedecem à estatística de Fermi-Dirac[1]. Este grupo é modelado sendo composto por duas partículas fundamentais, os quarks e os léptons. Um agrupamento de quarks é chamado de hádron. Por exemplo, um pión é um agrupamento de quarks descoberto por uma equipe da qual fazia parte o físico brasileiro César Lattes[2]. Já os léptons são partículas supostamente pontuais e sem estrutura interna, por exemplo, um elétron é classificado como lépton.

Os bósons são partículas que obedecem a estatística de Bose-Einstein e têm como característica a ruptura de uma lei da física clássica, uma quantidade infinita de bósons com energias idênticas pode estar contido em uma mesma região do espaço, o que os torna indistinguíveis[1]. Este grupo também é responsável pelas interações entre partículas, atuando como mediadores. Um exemplo de bóson é o fóton, que atua na interação eletromagnética.

Entretanto, o Modelo Padrão ainda não foi totalmente comprovado. Uma “peça” fundamental ainda continua oculta, a origem da massa de todas as partículas. Peter Higgs elaborou um teoria que completaria o Modelo Padrão, que é a existência de uma partícula, mais precisamente um bóson, que interagiria com todas as outras e essa interação teria como resultado a massa das partículas[3]. Para que esse modelo seja totalmente aceito, o bóson de Higgs, como é conhecido, deve ser observado experimentalmente. Na figura 2.1 é mostrada uma tabela com as forças descritas no modelo padrão.

	Fermions			Bosons	
Quarks	u up	c charm	t top	γ photon	Force carriers
	d down	s strange	b bottom	Z Z boson	
Leptons	ν_e electron neutrino	ν_μ muon neutrino	ν_τ tau neutrino	W W boson	
	e electron	μ muon	τ tau	g gluon	
				Higgs* boson	

Figura 2.1: Tabela com as forças do modelo padrão.

Neste contexto da física de altas energias, foram criados diversos laboratórios para a observação experimental de partículas de interesse, como por exemplo o bóson de Higgs. Dentre eles, destaca-se o CERN, que será mais detalhadamente exposto a seguir.



Figura 2.2: Visão Aérea do CERN.

2.1 CERN e o LHC

O Centro Europeu de Pesquisa Nuclear[4] criado no ano de 1954 e localizado a noroeste de Genebra, na fronteira da França com a Suíça, é o maior laboratório de física de partículas do mundo possuindo, atualmente, como principal objetivo a busca pelo Bóson de Higgs.

No CERN, encontram-se os maiores e mais complexos instrumentos científicos do mundo para pesquisa de partículas fundamentais. Esses são aceleradores e detectores de partículas. Os aceleradores impulsionam feixes de partículas para altas energias para que colidam umas com as outras ou contra alvos estacionários, enquanto detectores observam e gravam os resultados dessas colisões. O mais famoso acelerador é o LHC[5] que tem 27 km de perímetro e fará com que partículas possam colidir com até 14TeV no centro do ponto de colisão.

O LHC tem capacidade para acelerar partículas a 99,9999991% da velocidade da luz e, segundo os cálculos, seremos capazes de reconstruir um ambiente similar ao Universo apenas 10^{-12} s após o Big Bang, a suposta origem do Universo[6]. Em cada um dos pontos de colisão do LHC estão acoplados detectores. Os principais são: o ATLAS[7], o CMS[8], o LHCb[9] e o ALICE[10].

2.2 ATLAS

O ATLAS (A Toroidal Lhc ApparatuS) é um detector construído com propósito geral, ou seja, permite a leitura de diferentes tipos de interações. Tem 44 metros de




Figura 2.3: Detector de Partículas ATLAS.

comprimento por 25 de altura e aproximamente 7000 toneladas distribuídas em seu formato cilíndrico. O detector é formado por um conjunto de sub-sistemas, cada um com suas características próprias e uma infinidade de funcionalidades. Os principais são: o Inner Detector[11], o LAr[12], o TileCal[13] e o Muon System[14].

2.2.1 Sistema de Coordenadas do ATLAS

O detector ATLAS possui um sistema de coordenadas cilíndricas próprio[15], que visa facilitar os cálculos na área de física de altas energias. Suas coordenadas estão baseadas em duas variáveis: η e ϕ .

Primeiro, definiremos ϕ como sendo o ângulo formado pela projeção da trajetória da partícula no plano perpendicular ao eixo formado pelo feixe de partículas, no ponto de colisão, isto é, o ângulo radial e θ é o ângulo formado entre a projeção da trajetória da partícula e o plano paralelo ao eixo formado pelo feixe e que passa pelo ponto de colisão, como mostrado na figura 2.4.

Sendo assim, η é obtido através da equação 2.1. Como as duas coordenadas são baseadas em dois ângulos, podemos mapear qualquer ponto no espaço dentro

do detector.

$$\frac{\sigma(E)}{E} \approx \sqrt{\left(\frac{c1}{\sqrt{E}}\right)^2 + \left(\frac{c2}{E}\right)^2 + (c3)^2} \quad (2.1)$$

Por definição, o ATLAS foi dividido em duas partes para uma melhor manutenção e monitoramento. O lado A do detector representa o lado que possui η positivo, enquanto o lado C possui η negativo.




Figura 2.4: Sistema de Coordenadas do ATLAS.

2.2.2 Inner Detector, o detector de traços

O Inner Detector[16], que é a parte mais interior do detector, tem como principal objetivo a reconstrução da posição e momento de partículas carregadas provenientes das colisões em seu interior e, assim, permitir a reconstrução do traço, ou caminho das mesmas. Devido à sua alta resolução, que varia para cada um dos seus três sub-sistemas, o Inner Detector é capaz também de reconstruir os vértices, que por definição, são pontos onde ocorrem interações ou início de decaimento de partículas. O Inner Dectetor possui 7 metros de comprimento, 115 centímetros de diâmetro e com sua configuração cilíndrica cobre $|\eta| < 2.5$.

O primeiro sub-sistema do detector de traços, como também é conhecido o Inner Dectetor, é o Pixel Detector. Este sub-sistema é o que possui a mais fina




Figura 2.5: Visão Geral do Inner Detector.

resolução dentro do sistema, na ordem de 10^{-6} m. Utiliza uma estrutura de fibras de silício com $25\ \mu\text{m}$ de espessura como célula de leitura.

O segundo sub-sistema é o **Semi Condutor Tracker (SCT)** e possui a mesma estrutura de leitura do Pixel Detector, com células de fibra de silício semelhantes as do Pixel Detector. As células que compõem o SCT têm granularidade menos fina que as células que compõem o Pixel Detector, o que faz com que o SCT tenha uma resolução total menor. Somados, os dois primeiros sub-sistemas possuem 56 cm de diâmetro.

O último sub-sistema do Inner Detector é o **Transition Radiation Tracker (TRT)**, que é composto por 420000 fibras de 4 mm de diâmetro cada. Estas fibras são preenchidas por um material que se excita quando uma partícula o transpassa. A reação gerada pela partícula carregada ao passar pela fibra preenchida permite a leitura dos dados do traço nessa região. Cada fibra possui $170\ \mu\text{m}$ de resolução.

Além dos sub-sistemas, o Inner Detector está localizado dentro do solenóide do ATLAS, como mostrado na figura 2.5, isto é, o sistema de detecção de traços está sujeito ao campo de 2 Teslas gerado pelo solenóide.




Figura 2.6: Visão Geral do Muon System.

2.2.3 Muon System

O sistema de múon[17] é o sub-sistema mais afastado do ponto de colisão pertencente ao ATLAS, e tem por objetivos a reconstrução e identificação de traços dos múons, bem como, a medição de suas massas e seus momentos. Como múons são partículas que tem por característica uma pequena deposição de energia nos detectores que não são especializados em sua detecção[1], a presença de um sistema que possa fazer uma leitura mais precisa do sinal emitido pela passagem de um múon, se faz necessária. Uma visão geral do sub-sistema é mostrada na figura 2.6.

O sub-sistema consiste, primeiramente, em um sistema magnético central que trabalha em paralelo a outros dois end-caps magnéticos. Todos os três sistemas possuem a forma de um toróide. No total, este sistema magnético gera um campo de 0,5 Tesla de intensidade.

Além de um sistema magnético, o Muon System também é composto por 3 tipos de câmaras, como mostrado na figura 2.6, cada uma com funções e disposições bem definidas. As câmaras Monitored Drift Tube(MDT) são utilizadas para uma medição precisa da trajetória dos múons. As Resistive Plate Chambers(RPC) são utilizadas para filtragem enquanto as Cathode Strip Chambers(CSC) contribuem para a taxa de amostragem na região de end-cap.




Figura 2.7: Distribuição das câmaras do Muon System.

Capítulo 3

Calorimetria de Altas Energias

O termo “calorimetria” tem origem na termodinâmica, embora sua definição, na parte de física de altas energias, se refira a detecção de partículas e extração de suas características através de sua absorção total por um bloco de matéria, que é chamado de calorímetro [18]. Atualmente, existe uma quantidade relativamente grande de calorímetros em atividade, cada um com suas características próprias.

3.1 Tipos de Fenômenos de Detecção

Para que possamos realizar a leitura de energia das partículas, as mesmas devem interagir com os componentes do calorímetro e gerar um sinal de saída, também chamado de sinal de leitura. Estas interações podem se dar de diversas formas, tais como: a cintilação, a radiação de cherenkov, a ionização, os fenômenos criogênicos e o efeito de bremsstrahlung.

3.1.1 Cintilação

A cintilação ocorre quando partículas carregadas atravessam matéria. Uma vez que isso aconteça, essas partículas perdem energia através da interação eletromagnética com os campos que compõem a matéria que está sendo atravessada. A energia que é perdida ioniza os átomos e os coloca em estado de excitação. Átomos excitados são altamente instáveis, ou seja, eles tendem a rapidamente retornarem ao seu estado padrão e neste processo de retorno são liberados um ou mais fótons e o processo de emissão destes fótons é chamado Cintilação e pode ser visto na figura

3.1.




Figura 3.1: Partícula desenvolvendo uma cintilação.

3.1.2 Radiação de Cherenkov

A Radiação de Cherenkov é emitida quando partículas se movem a uma velocidade mais rápida do que a velocidade da luz em um determinado meio ($v_{part} > c/n$) e assim definimos β como $\beta \cong v/c$, onde n é o índice de refração do meio. Neste caso, as partículas perdem energia emitindo a chamada radiação de Cherenkov quando penetram no meio em questão.

Este tipo de radiação é emitida com um ângulo característico ($\theta_{cher} = \arccos(1/n\beta)$), o chamado ângulo de Cherenkov, assim sendo, esta radiação forma um cone com o ângulo de meia-abertura igual ao ângulo característico θ_c e emite a chamada luz ou radiação de Cherenkov e o esquema do processo de emissão pode ser visto na figura 3.2.

3.1.3 Ionização

Quando uma partícula carregada atravessa um meio, ela interage diretamente com os elétrons que estão na órbita dos átomos que compõem o meio, uma vez que estes elétrons adquirem uma quantidade de energia suficientemente grande para que

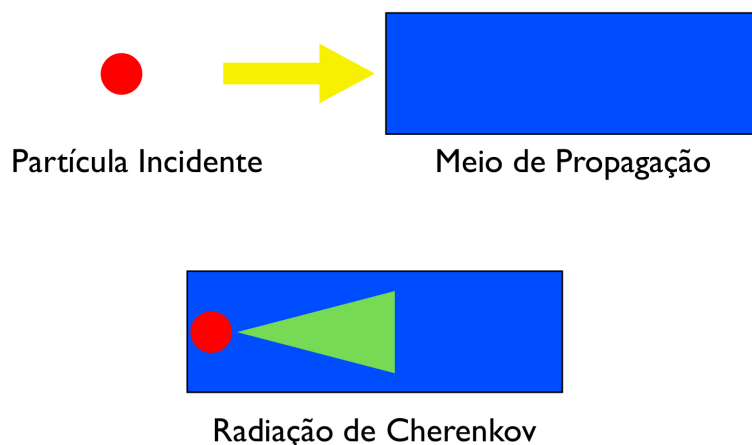


Figura 3.2: Partícula emitindo radiação de Cherenkov.

possam escapar do campo magnético do átomo, este átomo se torna um átomo ionizado, a este efeito chamamos Ionização e um exemplo deste mecanismo de interação pode ser encontrado na figura 3.3. Os elétrons liberados neste processo formam uma corrente elétrica que pode ser lida através de um sistema próprio.

Os Fenômenos Criogênicos são um conjunto de fenômenos, os quais são explorados quando a aplicação necessita de uma alta precisão. Este pacote de fenômenos é composto por 4 fenômenos, a seguir descritos:

- Algumas excitações elementares precisam de uma quantidade de energia muito baixa para serem rompidas, quando se encontram a baixas temperaturas, como por exemplo, ligações que se rompem com energias na faixa de $\mu eV - meV$.
- O calor específico de cristais dielétricos e de supercondutores se reduz a valores baixos quando expostos a baixas temperaturas.
- O ruído térmico nos detectores e nos componentes eletrônicos que compõem o sistema de leitura se reduz consideravelmente a baixas temperaturas.
- Alguns materiais apresentam um comportamento específico para baixas temperaturas.




Figura 3.3: Partícula desenvolvendo uma ionização.

3.1.4 Bremsstrahlung

O efeito de Bremsstrahlung se dá quando partículas carregadas, principalmente elétrons, interagem com o campo elétrico de núcleos de número atômico elevado, uma vez que isso ocorre, elas reduzem a sua energia cinética (velocidade) e podem mudar ou não de direção e como consequência emitem a diferença de energia sob a forma de ondas eletromagnéticas, denominadas raios δ de freamento ou “bremsstrahlung”, como pode ser visto na figura 3.4.

3.2 Tipos de Partículas

Existem dois tipos básicos de partículas: as eletromagnéticas e as hadrônicas no ambiente da física de altas energias. Quando uma partícula, independente do seu tipo, interage com um meio, a mesma gera um conjunto de reações em cadeia chamado de chuva.

O chuva eletromagnético pode ser produzido por:

- Cintilação, quando partículas carregadas excitam os átomos sem ionizá-los.
- Efeito Cherenkov, quando partículas viajam acima da velocidade da luz em um determinado meio.




Figura 3.4: Partícula emitindo raio de bremsstrahlung.

- Efeito Bremsstrahlung, quando partículas de altas energias se desaceleram rapidamente em um determinado meio.
- Partículas com energias muito elevadas penetram em um meio e produzem reações nucleares.

Para energias acima de 100 MeV, a principal forma de perda de energia para partículas eletromagnéticas é o efeito bremsstrahlung, pois quando um elétron decai em outros com menor energia estes elétrons irão gerar uma reação em cadeia gerando assim mais do efeito bremsstrahlung, com isso, seu espectro de energia decai com $1/E$.

O chuvaio hadrônico é desenvolvido pelas interações fortes entre partículas hadrônicas e os núcleos do material absorvedor. Devido a natureza da interação forte, os chuvaios hadrônicos são bem mais complicados do que os chuvaios eletromagnéticos.

3.3 Tipos de Calorímetros

Atualmente, existem dois tipos básicos de calorímetros: os homogêneos e os calorímetros de amostragem. Nos calorímetros homogêneos, todo o material que

constitui o calorímetro é sensível a interações com as partículas e por isso todo o material irá contribuir para os sinais produzidos pelo calorímetro, ou seja, todo o material que compõe o calorímetro irá absorver e detectar a energia produzida pelos subprodutos da colisão. Para que este material desempenhe estas duas tarefas, o mesmo deve possuir uma alta densidade.

Nos calorímetros de amostragem, apenas uma parte do material constituinte interage com as partícula. Este material é chamado material passivo e possui uma alta densidade (por exemplo ferro, chumbo ou urânio), já a outra parte do material é responsável por amostrar a informação de energia das partículas incidentes, este material é conhecido como material ativo e possui como forma de leitura um dos fenômenos de detecção descritos na seção 3.1.

Nos calorímetros de amostragem apenas uma fração da energia é amostrada para gerar o sinal de saída, como resultado deste fato, os calorímetros de amostragem, geralmente, apresentam respostas piores do que os calorímetros homogêneos pois para a reconstrução completa da energia é necessária a estimadação da energia depositada. Embora os calorímetros de amostragem são mais atraentes no sentido econômico que os calorímetros homogêneos, pois, geralmente, materiais ativos de alta densidade são mais caros que a intercalação d materiais ativos de baixa densidade e materiais passivos de alta densidade.

3.4 Parâmetros de Calorimetria

Nesta seção, os principais parâmetros de calorimetria serão abordados. Parâmetros como resolução em energia, granularidade e outros serão explicados.

3.4.1 Resolução em Energia

Este parâmetro fornece uma leitura da precisão com que o calorímetro fornece a medição da energia da partícula incidente e abrange as diversas flutuações estatísticas presentes na medição de energia feita pelo calorímetro. Diversos fatores entram na composição da resolução em energia e afetam diretamente a performance do detector.

A resolução está relacionada com as flutuações na resposta de energia do

calorímetro para partículas do mesmo tipo e mesma energia nominal. Em um calorímetro ideal, com comprimento infinito e homogêneo, temos que a resolução de energia só é influenciada pela quantidade de partículas que incide no calorímetro como mostrado na equação 3.1, onde N é o número de partículas, podemos definir também um fluxo de partículas, conhecido como η na equação 3.2, onde N_{MAX} é uma constante que depende do número de partículas e não dos componentes do detector, assim sendo, com esta nova variável podemos definir a resolução de energia de um calorímetro ideal como na equação 3.3.

$$\frac{\sigma(E)}{E} = 1/\sqrt[2]{N} \quad (3.1)$$

$$\eta = E/N_{MAX} \quad (3.2)$$

$$\frac{\sigma(E)}{E} = 1/\sqrt[2]{E} \quad (3.3)$$

Calorímetros reais geralmente são de amostragem e assim sendo detectam apenas uma parte da energia, possuem comprimento finito e como as partículas devem depositar toda a sua energia dentro do calorímetro, temos outro tipo de flutuação, a flutuação de amostragem, que degrada a resolução de energia. Empiricamente, temos que a resolução de energia de um calorímetro real, de amostragem, com comprimento finito é dada pela equação 3.4.

$$\frac{\sigma(E)}{E} \approx \sqrt{\left(\frac{c1}{\sqrt{E}}\right)^2 + \left(\frac{c2}{E}\right)^2 + (c3)^2} \quad (3.4)$$

3.4.2 Alcance em Posição

Para definirmos o alcance em posição precisamos tomar posse de uma informação contida no capítulo 2 seção 2.1, o sistema de coordenadas utilizado no ATLAS, bem como na grande maioria de experimento de física de partículas. De posse desta informação temos que o alcance em posição é o intervalo de valores de η ao qual o calorímetro consegue adquirir os dados da leitura de energia.

3.4.3 Granularidade

Este parâmetro é relacionado, basicamente, ao tamanho da unidade de leitura do calorímetro. É dado em função de η e ϕ . Expressa a precisão com a qual o calorímetro consegue detectar o traço ou caminho das partículas incidentes ou o local onde a sua energia foi depositada.

3.4.4 Efeitos da Não-Compensação

É o parâmetro que indica a razão entre a resposta da componente eletromagnética e da componente hadrônica das partículas hadrônicas incidentes. O parâmetro e/h não pode ser obtido diretamente das medições de energia feitas por um calorímetro, porém pode ser calculado a partir da razão e/π , que é a razão entre a energia medida de um elétron e a energia medida de um pión por um calorímetro hadrônico, como pode ser visto na equação 4.3. Onde f_{π^0} é definido na equação 4.4, k é uma constante e E é a energia da partícula incidente.

$$\frac{e}{\pi} = \frac{e/h}{1 + (e/h - 1)f_{\pi^0}} \quad (3.5)$$

$$f_{\pi^0} = k \cdot \ln(E) \quad (3.6)$$

Dizemos que um calorímetro é compensado quando $e/h = 1$, sendo assim a sua resposta é linear tanto para elétrons quanto para partículas hadrônicas. Quando temos diversos calorímetros em um mesmo sistema, é necessária a aplicação de uma calibração e inter-calibração dos calorímetros.

3.4.5 Tipos de Células de Leitura

Anteriormente, foi discutido quais as interações são utilizadas para que uma partícula seja lida, quais os tipos de partículas podem ser lidas e os parâmetros que a calorimetria se utiliza para classificar um calorímetro. Nesta subseção discutiremos os elementos que são responsáveis pela leitura da energia que será depositada em um calorímetro através dos fenômenos discutidos anteriormente.

Para que um sistema de leitura seja considerado efetivo, ele deve possuir duas características: seus efeitos para a precisão de energia, posição e medidas de tempo

deve ser desprezíveis e deve ser robusto a radiação.

3.4.5.1 Exemplo de um elemento de leitura

Um sistema de leitura que é amplamente utilizado na calorimetria de altas energias é o PMT. Para a aquisição da radiação proveniente de um evento, um tubo fotomultiplicador (PMT) é acoplado a um sistema de leitura que possua como resposta a emissão de fótons ou um tipo de radiação compatível com a faixa de leitura do PMT.

Os tubos foto-multiplicadores são dispositivos capazes de transformar radiação em sinal elétrico. A sua utilização permitiu que materiais que interagem com as partículas produzindo radiação, neste caso radiação luminosa, pudessem ser empregados na área de física de partículas. Os tubos foto-multiplicadores possuem uma grande vantagem em relação a outros dispositivos posteriormente desenvolvidos, pois a sua amplificação é feita com uma razão sinal-ruído muito difícil de ser superada.

Os tubos foto-multiplicadores possuem três componentes básicos para realizar a transformação de luz em sinal elétrico: o catodo, o ânodo e os dinodos. O catodo possui uma voltagem negativa e um material extremamente foto-sensível que absorve a luz e a transforma em elétrons. Os elétrons são acelerados em direção ao ânodo por conta da diferença de potencial, que cria um campo elétrico dentro do foto-multiplicador. No caminho, estes elétrons se chocam com os dinodos que estão progressivamente a potenciais mais altos, e cada um destes elétrons desloca aproximadamente 4 novos elétrons, que são acelerados até o próximo dinodo, como pode ser visto na figura 3.5. Dessa maneira, se um foto-multiplicador possui 10 estágios, isto é, 10 dinodos, um ganho de 10^6 pode ser atingido.

A voltagem aplicada aos foto-multiplicadores tem um papel fundamental na leitura e no cálculo da energia, pois o ganho dos foto-multiplicadores, isto é, a quantidade de elétrons gerados no ânodo, é proporcional à voltagem aplicada.

3.4.6 Calibração de um Calorímetro

Os calorímetros são detectores com a função de medir a energia de partículas que interagem com eles. A unidade usada nessa medição da energia é o GeV. A




Figura 3.5: Tubo foto-multiplicador em corte.

calibração de um calorímetro consiste na transformação do sinal gerado a partir da interação do detector com a partícula incidente para um valor na escala de energia de GeV. Tal transformação é feita através de constantes que são multiplicadas aos sinais medidos. As constantes de calibração dependem do tipo de sinal gerado pelo calorímetro. Se o sinal gerado pelo calorímetro é um sinal de carga, a constante é do tipo $GeV \cdot pC$.

Dentre os experimentos de colisão de partículas, muitos apresentam sistemas de calorimetria com mais de um tipo de calorímetro, um eletromagnético e outro hadrônico. O calorímetro eletromagnético, geralmente, fica posicionado entre o ponto de impacto e o calorímetro hadrônico, impedindo que elétrons e fótons alcancem o calorímetro hadrônico.

Logo, para um sistema de calorimetria, além da calibração de cada detector, é necessário que uma inter-calibração entre eles seja feita. Essa tarefa de inter-calibração pode trazer muitos problemas se alguns cuidados não forem tomados.

Esses problemas são acentuados em calorímetros não compensados, onde o sinal medido pelo detector para as componentes eletromagnéticas são diferentes do sinal medido para as componentes hadrônicas dentro do chuveiro gerado pelo decaimento de uma partícula hadrônica no detector. Essa dependência não é linear, tornando ainda mais árdua a tarefa de encontrar as constantes de calibração.

A calibração do calorímetro pode ser feita através de feixes monoenergéticos

de partículas com valores de energia conhecidos ou através de fontes radioativas que atravessam toda a extensão do calorímetro. Uma combinação de ambos métodos também é possível, onde um deles visa certificar a calibração feita pelo outro.

Para a calibração com feixes de partículas, distribuições do sinal medido pelo calorímetro são levantadas e as constantes de calibração são extraídas a partir da análise dos valores médios dessas distribuições. As partículas usadas para calibração podem ser elétrons, píons, prótons ou múons.

Para a calibração com fonte radioativa, uma fonte radioativa é circulada por todas as células do calorímetro e o sinal gerado é analisado. Essa análise permite que ajustes nos parâmetros do calorímetro sejam feitos trazendo o sinal medido mais próximo do valor desejado. Para calorímetros que utilizam tubos fotomultiplicadores, por exemplo, esse ajuste é feito nos valores da alta tensão que por sua vez alteram o seu ganho afetando a resposta do calorímetro.

3.5 Liquid Argon, o calorímetro eletromagnético do ATLAS




Figura 3.6: Visão Geral do Calorímetro Eletromagnético do ATLAS.

Como dito anteriormente, o sistema de calorimetria do ATLAS é composto pelos calorímetros de Argônio Líquido, também chamados de LAr; e pelo Tile Calorimeter, também chamado de TileCal. Os calorímetros de Argônio Líquido são divididos em uma parte central ou barril, dois end-caps e dois calorímetros especiais, chamados de Forward Calorimeters.

O sistema de calorimetria do ATLAS é um sistema de amostragem, isto é, apenas uma parte da energia das partículas será lida pelos sensores. Para que a amostra dessa energia seja feita, é necessária uma componente ativa e uma componente passiva.

Os calorímetros de Argônio líquido são divididos em várias partes: a parte central, também chamado de barril ou barril central, que cobre $|\eta| < 1,475$; o end-cap hadrônico, também chamado de HEC, que cobre $1,5 < |\eta| < 3,2$ e o forward calorimeter, também chamado de FCAL, que cobre $|\eta|$ entre 3,1 e 4,9. Em cada calorímetro temos diferentes materiais passivos bem como temos diferentes materiais ativos, que serão discriminados e explicados a seguir.

O LAr, os end-caps e os forward calorimeters possuem como material ativo, o argônio líquido. Como material passivo temos, chumbo no LAr, cobre nos end-caps e tungstênio nos forward calorimeters. Como o material de leitura é o Argônio líquido são necessárias câmaras criostáticas para manter o calorímetro na temperatura ideal de funcionamento. A escolha do Argônio líquido está diretamente ligada a robustez, no que concerne a radioatividade, da técnica de leitura do calorímetro e a redução da presença de ruído térmico.

O barril central é composto por 2 barris idênticos no formato de “acordeão”, como mostrado na figura 3.6. Todo barril é feito em 1024 camadas de metal intercaladas com 1024 eletrôdos de leitura e toda essa estrutura está comprimida entre 2 camadas de aço inoxidável, como mostrado na figura 3.7. Além disso, o barril central tem como característica uma boa precisão, isto é, tem a capacidade de determinar muito precisamente a quantidade de energia depositada e o ponto de sua deposição. A leitura dos dados provenientes do barril é feita em três camadas, que são chamadas de *front*, *middle* e *back*.




Figura 3.7: Células do LAr

3.6 TileCal, o calorímetro hadrônico do ATLAS




Figura 3.8: Visão Geral do Calorímetro Hadrônico do ATLAS.

O TileCal ou Tile Calorimeter foi desenvolvido para absorver a energia das partículas que possuem interações hadrônicas, sendo composto de 3 barris, um central, que tem aproximadamente 5,6 metros de extensão e outros dois externos com 2,9 metros, cada um, como pode ser visto na figura 3.8. Cada Barril Externo (*Extended Barrel - EBA e EBC*) possui 64 Super-Drawers que suportam toda a eletrônica necessária para a aquisição dos dados, também chamada de eletrônica de front-end. Cada Super-Drawer é por sua vez dividida em 2 Drawers (Interna e Externa) de

cerca de 1,5 metros de comprimento, facilitando assim seu manuseio e transporte. O Barril Central possui 128 Super-Drawers de modo a adquirir os dados dos seus 64 módulos de 5,6 metros de comprimento. Os Módulos do TileCal são dispositivos de amostragem, compostos por chapas de ferro (parte passiva) que se intercalam com chapas do material cintilante (parte ativa) que amostram a componente hadrônica das partículas que interagem com o detector ATLAS.

3.6.1 Cadeia de Leitura do TileCal

As partículas que possuem interações hadrônicas e incidirem no TileCal, excitarão o material cintilante que por sua vez emitirá luz[19]. A luz gerada por esse evento é diretamente proporcional a energia da partícula incidente. Esse sinal luminoso é captado por fibras ópticas, chamadas de “*Wavelength Shifting Fibers*” (WLS fibers). Essas fibras foram projetadas para mudar o comprimento de onda do sinal recebido.

As telhas cintilantes do TileCal, quando excitadas, emitem luz na faixa do azul/violeta, embora os PMTs tenham a resposta ótima na faixa do verde. As WLS fibers estão instaladas junto ao material cintilante seguindo uma organização pré-definida.

Cada sinal luminoso amostrado pelas telhas cintilantes é transmitido por duas fibras ópticas independentes, criando-se assim uma redundância do sinal amostrado. Estas fibras são organizadas seguindo uma formatação em células, como pode ser visto na figura 3.9(b) onde pode ser visto cada região dentro de um módulo. A estrutura de um modulo montado pode ser visto na figura 3.9(a). O agrupamento das fibras ópticas provenientes de uma célula é recebido como entrada por um único bloco fotomultiplicador[20], como mostrado na figura 3.10(a).

Uma vez que o sinal luminoso é recebido o bloco o transforma em um sinal elétrico, proporcional a intensidade luminosa recebida e que posteriormente será lido por um circuito eletrônico. Cada bloco fotomultiplicador é formado por um Light Mixer, uma PMT(modelo Hamamatsu R7877), um HV divider e uma placa 3em1[21]. O bloco fotomultiplicador é o primeiro elemento da eletrônica de front-end e é ilustrado na figura 3.10(b).

Cada PMT tem uma tensão nominal de operação e é nessa tensão que a





Figura 3.9: Módulo do TileCal.





Figura 3.10: Componentes do Calorímetro Hadrônico do ATLAS.

mesma opera com eficiência, isto é, atinge seu ganho nominal, que é da ordem de 10^6 . Como o modelo Hamamatsu possui tensões nominais variando entre 600 e 800 Volts, um sistema de alimentação foi desenvolvido.

Esse sistema consiste basicamente em três placas: a HVMicro, a HVOpto e a HVBus. A HVMicro possui os valores nominais de voltagem cada PMT em seu raio de ação e assim quando recebe aproximadamente 830 Volts do sistema de alimentação central, os repassa para a HVOpto juntamente com o valor de tensão e esta faz com que a PMT seja alimentada a partir da HVBus. Cada Drawer possui uma HVMicro e duas HVOpto e duas HVBus.

O sinal da PMT é lido pela placa 3em1, que possui três funções como o nome diz: i) Condicionar o sinal para ser integrado. ii) Permitir a injeção de carga para calibração e teste dos sistemas eletrônicos do TileCal. iii) Integrar o impulso de corrente(saída da pmt) para a saída em tensão em uma janela de tempo pré-definida.

A placa 3em1 possui 2 saídas primárias: uma para baixo ganho e outra para alto ganho. A saída de baixo ganho é lida pelos somadores produzidos pela UFRJ e pelos digitalizadores, enquanto a saída de alto ganho é lida apenas pelos digitalizadores. Os somadores integram o primeiro nível de validação de eventos do detector, este é responsável por determinar a 40MHz, se houve ou não algum evento relevante para análise.

O Digitalizador recebe o sinal de ganho alto e ganho baixo vindo de 6 placas 3em1 distintas, o que totaliza 60 bits de sinais, que são alinhados em uma pipeline aguardando a decisão do primeiro nível de validação. É no digitalizador onde é decidido se o sinal deve ser tratado como ganho baixo ou ganho alto. Se o evento for aceito, um número fixo de amostras será enviado através de um link de fibra óptica para os RODs(*“Read-Out Drivers”*) juntamente com o sinal de validação ou sinal TTC(*“Timing, Trigger and Control”*).

A eletrônica de back-end é composta por dois sistemas básicos: o ROD e a TTC. O sistema ROD é composto por 8 Optical Receivers(ORs), por 8 deserializadores HDMP, por 4 Staging FPGA, por 2 Processing Units(PU), 4 Output Controllers, uma VME FPGA e uma TTC FPGA. Já o sistema TTC é composto pela TBM, o LTP, a TTCvi, a TTCex, o TTCpr e pela ROD Busy. Ambos os calorímetros do detector ATLAS utilizam a mesma estrutura de leitura de dados, isto é, o mesmo

sistema ROD.

Os ORs recebem o sinal luminoso proveniente do último estágio da eletrônica de front-end e o transforma em sinal elétrico que será repassado para os deserializadores, que por sua vez, como o nome diz, irão deserializar o sinal através do chip HDMP-1024 com clock de 40 MHz. Uma vez que o sinal esteja deserializado, as Staging FPGAs criam uma rota direta para a entrada de dados provenientes de 4 ORs em uma única PU.

Cada ROD possui 4 PUs, pois foram inicialmente projetadas para atender as necessidades do calorímetro eletromagnético do ATLAS, mas seu projeto foi reutilizado para o calorímetro hadrônico. Sendo assim, para esta finalidade, são utilizadas apenas 2 PUs.

Cada PU é equipada com 2 DSPs do modelo TMS320C6414 @720MHz[22], 2 Input FPGAs, 2 FIFOs e uma Output FPGA. Cada DSP é responsável pelo processamento dos dados provenientes de 2 ORs, segundo um código previamente estabelecido, as Input FPGAs estão encarregadas de verificar se houve alguma corrupção dos dados recebidos e por um pré-processamento que preparará os dados para os DSPs.

A Output FPGA é responsável pelo armazenamento dos eventos na FIFO, que suporta até 16 eventos. A FIFO só pode enviar seus eventos para o Output Controller quando receber o sinal de validação gerado pela TTC e enviado através do barramento VME para a Output FPGA.

O Output Controller é o responsável por exportar os dados do sistema ROD. Uma vez que o sistema receba o sinal de aceitação do evento, o OC gera uma estrutura de compactação de dados chamada ROD Fragment que contem as informações sobre o evento lido pelo TileCal. Após o sinal de aceitação do evento essa estrutura é exportada, através de um link VME, a taxa máxima de 75kHz.

3.6.2 Regiões sem leitura

Como dito anteriormente, para manter o calorímetro eletromagnético do ATLAS na temperatura ideal de operação são necessárias câmaras criostáticas. Além das câmaras criostáticas, cabos de alimentação e outros equipamentos se encontram dentro do TileCal, o que gera regiões dentro do calorímetro que não são instrumen-

tadas, isto é, regiões onde se deposita energia, mas não se tem leitura da energia depositada.

Essencialmente, o TileCal é um instrumento de medida e, como tal, deve apresentar resposta linear. Nos pontos próximo de regiões com materiais mortos (onde não temos leitura devido a passagem de materiais pelo calorímetro), encontramos uma resposta altamente não linear, pois a energia depositada nestas regiões depende diretamente da energia depositada em uma área sem instrumentação. A grosso modo, podemos dizer que as regiões de materiais mortos aumentam a não-linearidade do sistema de calorimetria.

Na região do “crack” entre os calorímetros($1.3 < |\eta| < 1.8$), isto é, na região onde temos uma maior concentração de materiais mortos. Na figura 3.11 é mostrada a configuração do ATLAS em um corte longitudinal, sendo removido o TileCal. Nesta figura vemos claramente que uma parte dos componentes de alimentação e outros componentes do LAr penetram no espaço aonde deveríamos encontrar o TileCal. Já na figura 3.12 é mostrado o mesmo corte longitudinal com o TileCal e os elementos de alimentação.

Neste cenário, a energia depositada nesta região deve ser estimada para uma posterior compensação. As técnicas utilizadas até agora pela colaboração CERN/ATLAS para esta estimativa serão apresentadas no próximo capítulo.

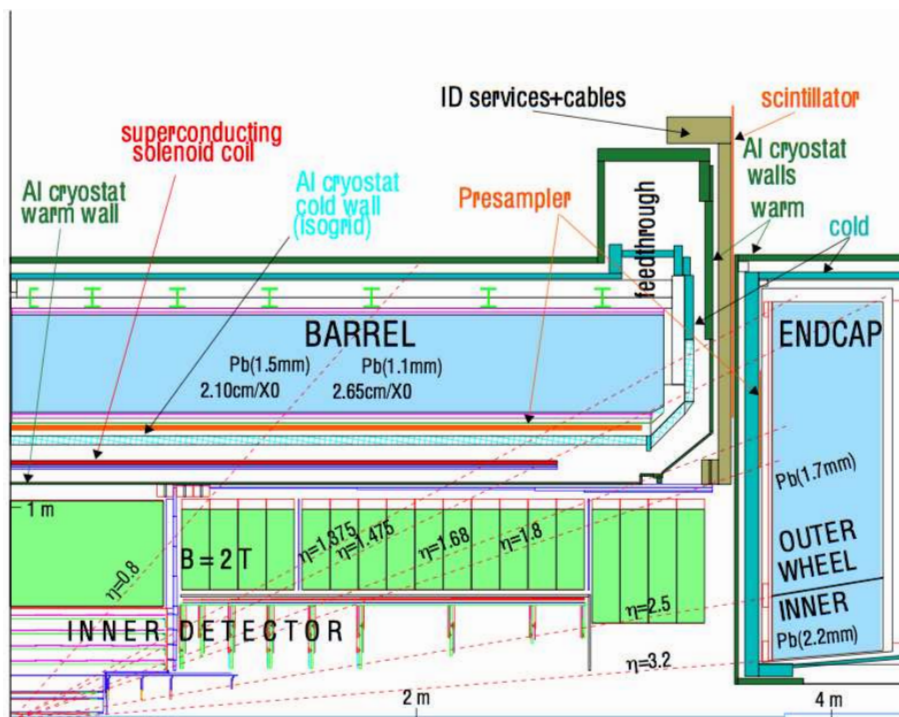


Figura 3.11: Vista longitudinal do ATLAS sem o TileCal




Figura 3.12: Vista longitudinal do ATLAS com o TileCal

Capítulo 4

Estimador Neural de Energia para Regiões com Materiais sem Leitura

Em geral, uma rede neural biológica é composta por um grupo ou grupos de neurônios química ou funcionalmente ligados. Um único neurônio pode ser ligado a muitos outros e o número total de neurônios e/ou conexões em uma rede pode ser bastante extenso.

O conceito de redes neurais artificiais remonta ao final do século XIX [23], como um esforço para descrever a forma como a mente humana responde a determinados estímulos. Estas idéias começaram a ser aplicadas em modelos computacionais a partir da criação de computadores com poder de processamento compatível com as necessidades do modelo.

O modelo Perceptron Multi-camada, ou MLP [23] é um modelo de rede neural artificial que mapeia um conjunto de variáveis de entrada em um conjunto de variáveis de saída. Este modelo, que é uma modificação do padrão perceptron [24], utiliza duas ou mais camadas de neurônios com funções de ativação diversas, e é mais poderoso do que o perceptron, pois pode distinguir classes de dados que não são linearmente separáveis.

No campo inteligência computacional, as redes neurais artificiais têm sido aplicadas com sucesso para o reconhecimento de fala[25], análise de imagens[26], controle adaptativo[27] e outras áreas de pesquisa. As redes neurais também têm

sido utilizadas na área da física de altas energias com bons resultados[6, 28, 29].

O TileCal, por ser uma ferramenta de medida não ideal, possui imprecisões que devem ser compensadas. Com esse intuito, em [6] foi desenvolvida uma rede neural MLP que possuía como entradas as energias depositadas em cada célula do TileCal, como saída a energia total depositada no calorímetro e utilizava como alvo um modelo de alvos estocásticos que mapeava a energia nominal de um feixe de partículas.

Para a análise da resposta do calorímetro e consequentemente a resposta do estimador neural de energia do TileCal, são utilizadas duas figuras de mérito: a linearidade e a resolução de energia.

A linearidade está diretamente ligada a técnica de medida e a implementação do sistema de calorimetria, por este motivo são utilizados estimadores de energia que visam melhorar a linearidade da resposta do calorímetro.

Com o modelo de estimador neural apresentado em [6], foi constada uma melhora tanto na resolução em energia quanto na linearidade da resposta do TileCal.

A estimativa da energia na região sem leitura é importante para uma melhor resposta do calorímetro como um todo, pois como a resposta neste região é não linear, a deposição de energia nesta região aumenta a não linearidade presente na resposta do calorímetro.

4.1 Modelos Anteriores

A colaboração CERN/ATLAS [30] utiliza como modelo de referência para a energia depositada na região sem leitura, a média geométrica entre as duas camadas com leitura mais próximas da região sem leitura, isto é, E_{LAR3} e E_{Tile1} , escalada por uma constante, que chamaremos de c_{dm} . A figura 4.1 mostra o resultado deste modelo utilizado pela colaboração para feixes de píons com diferentes energia disponibilizadas.

Para a determinação da constante de calibração utilizamos a equação 4.1, onde $\langle E_{DMtrue} \rangle$ é a média da distribuição da energia simulada para a região sem leitura do calorímetro e $\langle E_{DMcalc} \rangle$ é a média da distribuição da energia calculada através do modelo da colaboração para a mesma região. Para o cálculo, neste traba-

lho, foram utilizados 5000 eventos para a estimativa dos desvios-padrão das distribuições de $\sqrt[2]{E_{LAr3} \cdot E_{Tile1}}$ e E_{DMtrue} ; e utilizamos esta informação em conjunto com a média para o calculo de c_{dm} . Para as energias disponibilizadas pela colaboração, temos os valores obtidos para c_{dm} na figura 4.2.

$$\langle E_{DMtrue} \rangle = \langle E_{DMcalc} \rangle = c_{dm} \langle \sqrt[2]{E_{LAr3} \cdot E_{Tile1}} \rangle \quad (4.1)$$




Figura 4.1: Energia depositada na região sem leitura estimada com o modelo de referência para diferentes energias.




Figura 4.2: Valores da constante de calibração c_{dm} para diferentes energias.

Dentro do contexto da colaboração, foram realizados alguns testes com redes neurais para a estimação neural de energia na região sem instrumentação [28], visando melhorar a resposta obtida através do modelo de referência.

Para a realização destes testes, foram utilizadas diversas topologias de redes neurais baseadas em MLP e estas topologias serão exemplificadas a seguir.

Estas experiências foram realizadas utilizando um ambiente de criação e treinamento para redes neurais disponibilizado, também, pelo CERN, o JetNet 3.0. O JetNet 3.0 é um pacote, baseado na linguagem de programação FORTRAN e fornece diversas sub-rotinas para a criação, treinamento e testes das redes neurais, possuindo um grande número de algoritmos de treinamento e ferramentas para a melhora de performance.

Na tabela 4.1 temos um resumo de todas experiências e suas configurações básicas que foram realizadas em [28]. Para este conjunto de testes, foram utilizados diversos tipos de entradas, como pode ser visto na tabela 4.1. Onde E_{LAr1} , E_{LAr2} e E_{LAr3} são as energias depositadas na primeira, segunda e terceira camadas do LAr, respectivamente, e E_{Tile1} , E_{Tile2} e E_{Tile3} são as energias depositadas na primeira, segunda e terceira camadas do TileCal, respectivamente.

Durante a realização destes testes, para efeito de simplificação, diversos tipos de variáveis foram agrupadas em níveis. Estes agrupamentos de variáveis, por sua vez, foram inseridos como entradas nas redes neurais. O nível mais básico de agrupamento é o nível 1, que é composto pelas energias das quatro células com maior deposição de cada uma das camadas mais próximas a região sem instrumentação durante a aquisição do evento, totalizando 8 variáveis neste nível ou agrupamento.

O segundo nível de agrupamento é o nível 2 e é composto pelas informações contidas no nível 1 somadas com outras duas variáveis, que são: o número de células que foram ativadas durante o evento em cada uma das camadas, totalizando 10 variáveis neste nível. O terceiro e último agrupamento de variáveis é a união do nível 2 com outras duas variáveis que fornecem o grau com que a energia se espalha dentro do detector. Esta grandeza foi medida experimentalmente e aproximada pela colaboração na equação 4.2, onde e_i é a energia na i -ésima célula de leitura amostrada.

$$Spread = \left(\sum_i e_i^2 \right) \cdot \left(\sum_i e_i \right)^2 \quad (4.2)$$

Número do Experimento	Energia (GeV)	Entradas	Número de Épocas	Quantidade de Neurônios na 1ª camada escondida	Quantidade de Neurônios na 2ª camada escondida
1	250	$E_{LA3} + E_{Tile1}$	500	1	-
2	250	$E_{LA3} + E_{Tile1}$	1500	12	-
3	250	$E_{LA3} + E_{Tile1} + \text{Nível 1}$	2000	20	20
4	250	$E_{LA3} + E_{Tile1} + \text{Nível 2}$	2000	24	20
5	250	$E_{LA3} + E_{Tile1} + \text{Nível 3}$	2500	28	20
6	250	$E_{LA3} + E_{Tile1} + E_{Tile2} + \text{Nível 2}$	2500	26	20
7	250	$E_{LA3} + E_{LA2} + E_{Tile1} + \text{Nível 2}$	2500	26	20
8	250	$E_{LA3} + E_{LA2} + E_{Tile1} + E_{Tile2} + \text{Nível 2}$	2500	26	20
9	250	$E_{LA3} + E_{LA2} + E_{LA1} + E_{Tile1} + E_{Tile2} + E_{Tile3} + \text{Nível 2}$	2500	28	20
10	250	$E_{LA3} + E_{LA2} + E_{Tile1} + E_{Tile2}$	5000	10	10
11	250	$E_{LA3} + E_{LA2} + E_{LA1} + E_{Tile1} + E_{Tile2} + E_{Tile3}$	3000	15	15
12	250	$E_{LA3} + E_{LA2} + E_{LA1} + E_{Tile1} + E_{Tile2} + E_{Tile3} + \text{Nível 2}$	3000	11	11
13	10	$E_{LA3} + E_{LA2} + E_{LA1} + E_{Tile1} + E_{Tile2} + E_{Tile3}$	2000	11	11
14	10	$E_{LA3} + E_{LA2} + E_{LA1} + E_{Tile1} + E_{Tile2} + E_{Tile3}$	2000	15	15
15	50	$E_{LA3} + E_{LA2} + E_{LA1} + E_{Tile1} + E_{Tile2} + E_{Tile3}$	3000	15	15
16	350	$E_{LA3} + E_{LA2} + E_{LA1} + E_{Tile1} + E_{Tile2} + E_{Tile3}$	6000	15	15

Tabela 4.1: Resumo das topologias testadas pela colaboração CERN/ATLAS com suas especificações.

4.2 Estimador Neural de Energia

Neste seção veremos a metodologia utilizada para o projeto do estimador neural. Aqui se encontram informações como os dados que foram utilizados, as entradas e saídas aplicadas aos estimadores e o tipos de treinamentos que foram realizados durante os testes.

4.2.1 Dados utilizados

Em 2004, foi montada, com o objetivo de realizar testes e calibrações, uma “fatia” de cada subdetector do ATLAS, como mostrado na figura 4.3 e este conjunto de teste foi chamado de CTB04. Esta configuração foi submetida a uma série de testes com feixes de píons, que foram gravados e reconstruídos para análise. As energias nominais destes feixes que foram disponibilizadas são: 10, 20, 100, 150, 180, 250, 320 e 350 GeV.

Nesta configuração, o LAr é representado por 3 camadas radiais que somadas possuem 6,65m de comprimento e 53,4cm de largura. A primeira camada possui granularidade de $\Delta\eta \times \Delta\phi = 0,025 \times 0,0245$ e espessura de 13,35 cm. A segunda é mais ampla e possui 35,6 cm de espessura e granularidade de $\Delta\eta \times \Delta\phi = 0,05 \times 0,025$. A terceira e última camada possui 4,45 cm de espessura e granularidade de $\Delta\eta \times \Delta\phi = 0,025 \times 0,1$.

O calorímetro hadrônico é representado, nesta configuração, por três módulos de leitura como os já descritos no capítulo 3. As duas primeiras camadas de leitura, neste caso, possuem granularidade de $\Delta\phi = 0,1 \times 0,1$, enquanto a terceira possui granularidade de $\Delta\phi = 0,2 \times 0,1$ e como dito anteriormente estes módulos são formados pela intercalação de ferro com telhas cintilantes e possuem como célula de leitura os blocos PMT.

Para a verificação dos resultados obtidos com os testes experimentais, foram simulados feixes de píons para as mesmas energias nominais e com a mesma configuração espacial descrita anteriormente. A simulação dos eventos foi baseada no método de Monte Carlo[31] e as interações das partículas com a fatia do detector foram simuladas com o Geant4.

O Geant4[32] é uma ferramenta que possui uma descrição detalhada do detector, isto é, uma descrição da geometria do detector, seus componentes e cada uma de suas sub-estruturas. De posse destas informações, o Geant4 propaga, pelo detector virtual, as partículas geradas e seus subprodutos virtualmente pelo gerador.

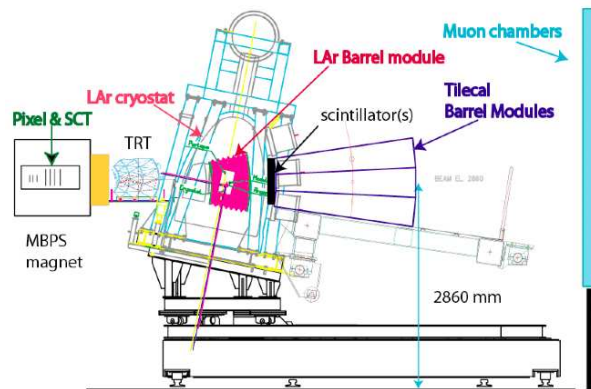


Figura 4.3: Configuração básica do TestBeam.

4.2.2 Entradas e saídas utilizadas

Como o objetivo deste projeto é melhorar o modelo de referência utilizado pela colaboração, isto é, obter uma resposta melhor do que $E_{dm} = c_{dm} \sqrt[2]{E_{LAr3} \cdot E_{Tile1}}$ os primeiros testes foram realizados utilizando como entrada E_{LAr3} e E_{Tile1} , visando assim comprovar que o melhor mapeamento para E_{dm} é a média geométrica, como foi proposto pela colaboração.

Em [28], a inserção de variáveis que continham mais informações sobre a deposição de energia do evento nos detectores trouxe um melhor desempenho para os estimadores de energia testados. Com esta motivação, foram testados diversos tipos de entradas, buscando a configuração de entradas para o estimador de energia que fornecesse a melhor resposta.

Primeiramente, utilizando um conjunto mais pobre de informações como entrada e posteriormente adicionando grande parte da energia depositada no sistema de calorimetria. Todas as variáveis de entrada foram normalizadas pela soma das energias depositadas nas camadas próximas a região sem instrumentação. Esta normalização se faz necessária para evitar que haja uma saturação nos neurônios de entrada. As distribuições da energia da última camada do LAr e da primeira camada do TileCal, para um feixe de 100GeV de energia nominal, estão expostas nas figuras 4.4 e 4.5 respectivamente, já a energia depositada nas demais camadas pode ser vista no conjunto de figuras 4.6.




Figura 4.4: Energia normalizada na última camada do LAr







Figura 4.5: Energia normalizada na primeira camada do Tile




(a) Energia normalizada na primeira camada do LAr



(b) Energia normalizada na segunda camada do LAr



(c) Energia normalizada na segunda camada do Tile



(d) Energia normalizada na terceira camada do Tile

Figura 4.6: Energias depositadas em camadas do sistema de calorimetria.

Além das energias depositadas nas camadas mais próximas da região de materiais mortos, foram utilizadas as energias de um conjunto de células “quentes” (as células do calorímetro que receberam a maior quantidade de energia individualmente durante o evento) e também a energia depositada em outras camadas pertencentes ao sistema de calorimetria.

Embora uma grande variedade de variáveis fossem aplicadas a entrada das redes durante os testes, a saída sempre representa a energia estimada normalizada e o neurônio de saída possui como função de ativação a função linear. E um exemplo do alvo adotado para o treinamento des estimado usado para 100GeV pode ser visto na figura 4.7.




Figura 4.7: Energia simulada como alvo para a rede neural com feixe de 100GeV

4.2.3 Treinamento e Camadas Escondidas

Para o projeto do estimador neural, foram testadas seis diferentes redes neurais, uma para cada uma das energias disponibilizadas pela colaboração CERN/ATLAS. As redes foram treinadas com o algoritmo back-propagation, tendo como alvo a energia obtida por simulação para a região sem leitura. Foram utilizados dois métodos de atualização de pesos: o Steepest Descent[33] e o BFGS[34]. O primeiro utiliza o gradiente para atualizar os pesos de cada neurônio. O segundo calcula a matriz Hessiana para obter uma aproximação da derivada segunda e a utiliza para atualizar os pesos.

Para a criação e desenvolvimento das redes neurais foi utilizado um pacote de desenvolvimento pertencente a ferramenta de análise ROOT, disponibilizada pelo CERN. Este pacote oferece todo o suporte para a criação e treinamento de redes neurais, embora durante o projeto tenha sido necessário a criação de uma interface em C++ para a extração dos resultados obtidos.

Para o treinamento foram utilizados dados simulados com a estrutura do CTB04, pois com dados simulados poderíamos ter mais controle sobre as flutuações estatísticas presentes na entrada dos estimadores. Os dados foram divididos da seguinte forma: 5000 eventos para treinamento e 5000 eventos para teste. O critério de parada utilizados foi o número de épocas do treinamento.

Os primeiros testes utilizaram apenas uma camada escondida, embora em trabalhos anteriores [35], foi constatado que o uso de 2 camadas escondidas permite um melhor desempenho para baixas energias, a faixa de energia em que o sistema de calorimetria possui uma pior resolução e uma maior não-linearidade.

4.3 Figuras de Mérito

Para os resultados mostrados nesse projeto, adotaremos duas figuras de mérito: o ganho absoluto e o ganho relativo. O ganho absoluto expressa o ganho do modelo neural, tendo como referência a energia reconstruída da simulação, como mostrado na equação 4.3, onde E_{DMtrue} é a energia simulada para a região sem leitura, E_{DMcalc} é a energia estimada pelo modelo padrão e $E_{DMneural}$ é a energia estimada pela rede neural treinada. O ganho relativo expressa o ganho do modelo neural em relação ao modelo adotado pela colaboração CERN/ATLAS (equação 4.4).

Na figura 4.8 temos o resultado obtido para 100GeV, com os respectivos valores de ganhos obtidos. Nesta figura, o gráfico em verde mostra a distribuição $E_{DMreal} - E_{DMcolab}$, enquanto o gráfico em vermelho representa a distribuição $E_{DMreal} - E_{DMneural}$. As técnicas aplicadas neste trabalho buscam maximizar as duas figuras de mérito.

Os valores das distribuições $E_{DMtrue} - E_{DMcalc}$ e $E_{DMtrue} - E_{DMneural}$ são calculados evento a evento, isto é, de cada evento é extraída a informação de cada energia e assim as distribuições de $E_{DMtrue} - E_{DMcalc}$ e $E_{DMtrue} - E_{DMneural}$ podem

ser estimadas. Com estas distribuições podemos retirar o valor do desvio-padrão e assim calcularmos os ganhos absoluto e relativo.

$$Ganho\ Absoluto = RMS(E_{DMtrue} - E_{DMcalc}) - RMS(E_{DMtrue} - E_{DMneural}) \quad (4.3)$$

$$Ganho\ Relativo = \frac{Ganho\ Absoluto}{RMS(E_{DMtrue} - E_{DMcalc})} \quad (4.4)$$




Figura 4.8: Exemplo de resultado de uma rede neural e um feixe de 100GeV.

Para a avaliação dos estimadores, utilizaremos os resultados obtidos pela colaboração, através dos ganhos absoluto e relativo, e os resultados obtidos em [28], que são expressos na tabela 4.2.

Na tabela 4.2 são apresentados os resultados para 16 experimentos com redes neurais realizados pela colaboração. Nesta tabela, as experiências são representadas por números que variam de 1 a 16. As primeiras 12 experiências foram feitas se utilizando um feixe de píons de 250 GeV. As experiências 13 e 14 foram realizadas utilizando um feixe de 10 GeV de energia nominal, já a experiência 15 utilizou um feixe de 50 GeV e a experiência 16 se utilizou de um feixe de 350 GeV.

Para este conjunto de experimentos foram utilizados 19159 eventos para o treino dos estimadores e 6000 para teste. O número de épocas de cada um dos experimentos está exposto na figura 4.1.

Ganho	Número da Experiência							
	1	2	3	4	5	6	7	8
Absoluto	-1,23 GeV	0,31 GeV	1,49 GeV	1,53 GeV	1,58 GeV	1,75 GeV	2,01 GeV	2,95 GeV
Relativo	-16,3%	4,1%	19,7%	20,3%	21%	23,2%	27%	39,2%

Ganho	Número da Experiência							
	9	10	11	12	13	14	15	16
Absoluto	3,28 GeV	0,31 GeV	2,59 GeV	2,85 GeV	0,47 GeV	0,42 GeV	0,93 GeV	5,59 GeV
Relativo	43,6%	4,1%	34,3%	37,8%	42,0%	37,5%	35,5%	41,2%

Tabela 4.2: Ganhos para os experimentos com redes neurais na estimativa da energia na região sem leitura, realizados anteriormente pela colaboração CERN/ATLAS

4.4 Resultados

Os resultados serão expostos nesta seção, começamos com os estimadores com apenas uma camada escondida, passando, posteriormente, para os estimadores com duas camadas escondidas.

4.4.1 Redes Neurais com uma camada escondida

Para o caso de duas entradas, isto é, utilizando, E_{Tile1} e E_{LAr3} como entradas e o algoritmo de primeira ordem, o Steepest Descent, obtivemos os resultados expostos na tabela 4.3.

Energia	Topologia					
	2 - 2 - 1		2 - 12 - 1		2 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,23 GeV	12,48%	0,31 GeV	16,71%	0,30 GeV	16,35%
100 GeV	0,39 GeV	8,23%	0,33 GeV	6,97%	0,38 GeV	8,09%
150 GeV	0,98 GeV	14,21%	1,19 GeV	17,22%	1,06 GeV	15,25%
180 GeV	1,79 GeV	21,04%	1,51 GeV	17,80%	1,95 GeV	22,96%
320 GeV	4,82 GeV	30,93%	4,93 GeV	31,61%	5,01 GeV	32,15%
350 GeV	5,56 GeV	33,94%	6,00 GeV	35,99%	5,97 GeV	35,79%

Tabela 4.3: Ganhos para duas entradas utilizando o algoritmo Steepest Descent.

Na tabela 4.3, pode ser observada uma melhora na resposta dos estimadores a medida que temos um aumento na energia, sendo este comportamento, resultado da melhor resposta do sistema de calorimetria para energias mais elevadas. O mesmo comportamento é observado quando aumentamos o número de neurônios na camada escondida, com este resultado vemos que talvez exista um melhor mapeamento para E_{dm} que seja diferente de $c_{dm}\sqrt[2]{E_{LAr3} \cdot E_{Tile1}}$.

Comparando-se os resultados expostos na tabela 4.3 com os resultados obtidos em [28], vemos que para o mesmo tipo de entrada, ou seja, E_{LAr3} e E_{Tile1} como entradas do estimador, o estimador treinado com o algoritmo Steepest Descent obteve um melhor resultado.

Quantitativamente, temos 0,31 GeV de ganho absoluto para um estimador treinado com um feixe de 250 GeV contra 1,19 GeV de ganho absoluto para um estimador treinado com um feixe de 180 GeV (que possui a tendência a ter um ganho absoluto menor devido a resposta do calorímetro). Encontramos o mesmo resultado quando comparamos o ganho relativo, temos 4,1% no primeiro caso, contra 17,22% como pode ser visto na tabela 4.3.

Em seguida, o treinamento de segunda ordem, BFGS, foi implementado. Na tabela 4.4 temos os resultados obtidos para este algoritmo de treinamento.

Energia	Topologia					
	2 - 2 - 1		2 - 12 - 1		2 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,32 GeV	17,3%	0,34 GeV	18,04%	0,34 GeV	18,01%
100 GeV	0,60 GeV	12,63%	0,65 GeV	13,75%	0,64 GeV	13,68%
150 GeV	1,50 GeV	21,73%	1,55 GeV	22,34%	1,57 GeV	22,62%
180 GeV	2,48 GeV	29,16%	2,51 GeV	29,56%	2,51 GeV	29,53%
320 GeV	6,43 GeV	41,22%	6,43 GeV	41,24%	6,4 GeV	41,05%
350 GeV	7,54 GeV	45,18%	7,54 GeV	45,24%	7,4 GeV	44,40%

Tabela 4.4: Ganhos para duas entradas utilizando o algoritmo BFGS.

Ao implementarmos os estimadores com o algoritmo BFGS, observamos uma elevação geral no valor dos ganhos absoluto e relativo. Quando comparamos os resultados da tabela 4.4 com os resultados obtidos com o treinamento de primeira ordem (tabela 4.3), encontramos uma melhora. O que motiva os testes com ambos os algoritmos, para a sua posterior comparação e mais uma vez vemos que a

média geometrica, proposta pela colaboração CERN foi superada pelos estimadores neurais.

Na figura 4.9 podemos ver o comportamento do ganho absoluto a medida que inserimos neurônios na camada escondida e também modificamos o algoritmo de treinamento de primeira para segunda ordem. Na figura 4.10 vemos o comportamento do ganho relativo para as mesmas condições.

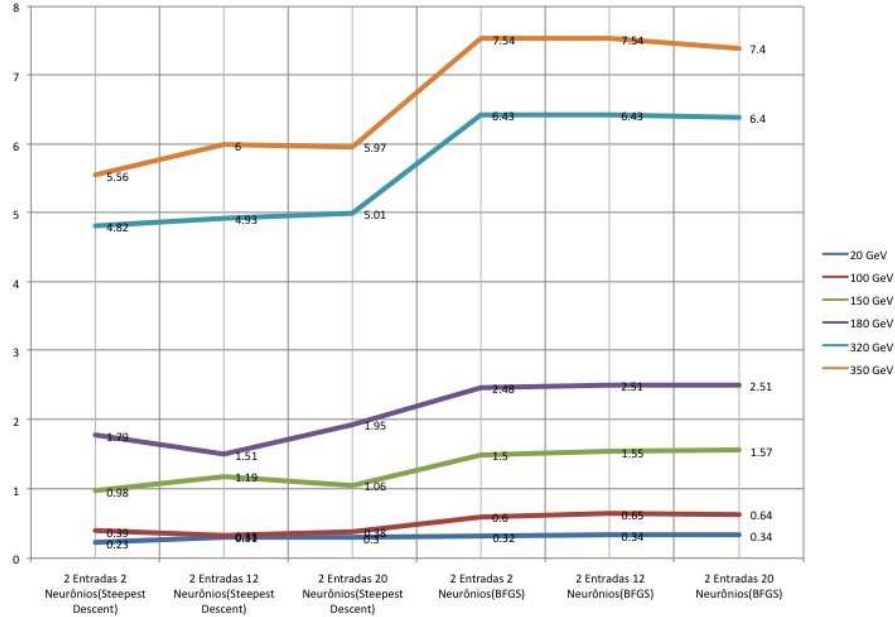


Figura 4.9: Ganho absoluto para um estimador com 2 entradas, diferentes energias e diferentes topologias.

De posse destes resultados, foram consideradas outras variáveis para a entrada dos estimadores. O primeiro conjunto de variáveis escolhido foi a célula com maior energia de das camadas mais próximas da região de materiais mortos para cada evento.

Como estamos lidando o dados simulados de um feixe de píons sendo aprontado para uma região do detector, temos que a célula de maior energia deve ser a célula que se encontra no centro da incidência feixe, como pode ser visto na figura 4.11, no caso do LAr e na figura 4.12 no caso do TileCal.

A tabela 4.5 expressa os resultados de uma rede neural treinada com as 4 entradas; as duas energias das camadas de leitura anteriormente usadas, em conjunto com duas maiores energias destas camadas. O algoritmo utilizado foi o Steepest

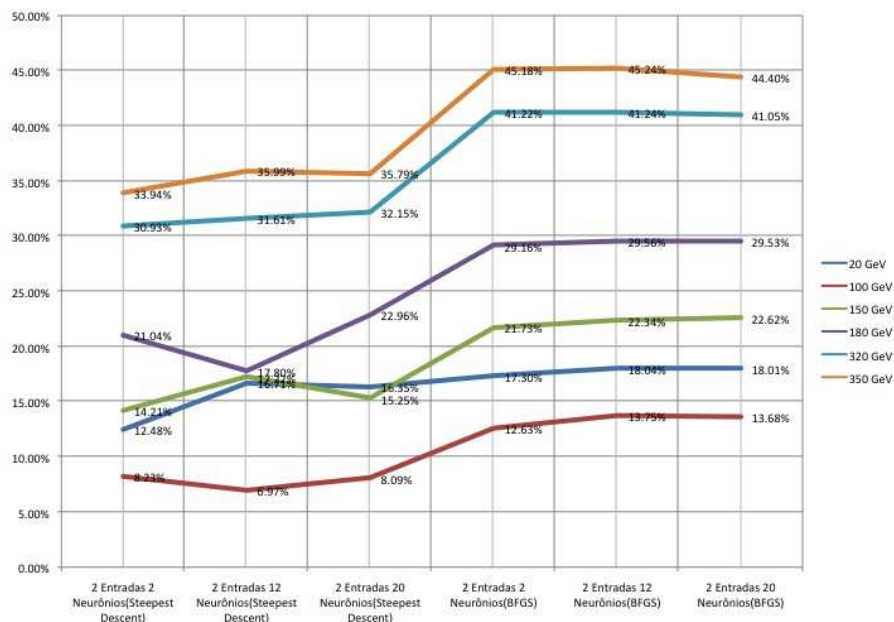


Figura 4.10: Ganho relativo para um estimador com 2 entradas, diferentes energias e diferentes topologias.




Figura 4.11: Distribuição espacial de Energia na última camada do LAr




Figura 4.12: Distribuição espacial de Energia na primeira camada do TileCal

Descent. Já a tabela 4.6 mostra os resultados referentes ao algoritmo BFGS com as mesmas entradas.

Neste ponto, notamos que as variáveis adicionadas possivelmente fazem parte do mapeamento ideal da energia a ser estimada, uma vez que com a adição deste conjunto de variáveis obtivemos uma melhora de 43% com relação ao estimador anterior, quando comparamos o feixe de energia de 180GeV. Este resultado nos motivou a inserir ainda mais informações sobre o sistema de calorimetria nos estimadores.

Energia	Topologia					
	4 - 2 - 1		4 - 12 - 1		4 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,5 GeV	27,05%	0,51 GeV	27,5%	0,52 GeV	27,68%
100 GeV	0,89 GeV	18,87%	0,96 GeV	20,27%	0,89 GeV	18,98%
150 GeV	1,52 GeV	21,99%	1,84 GeV	26,63%	1,9 GeV	27,42%
180 GeV	2,68 GeV	31,56%	2,75 GeV	32,36%	2,79 GeV	32,88%
320 GeV	6,13 GeV	39,35%	6,29 GeV	40,36%	6,22 GeV	39,88%
350 GeV	7,31 GeV	43,85%	7,33 GeV	43,93%	7,33 GeV	43,94%

Tabela 4.5: Desempenho para quatro entradas e método de treinamento Steepest Descent.

Para os testes realizados com 4 entradas e o algoritmo de segunda ordem, o

Energia	Topologia					
	4 - 2 - 1		4 - 12 - 1		4 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,54 GeV	29,1%	0,55 GeV	29,76%	0,55 GeV	29,56%
100 GeV	1,08 GeV	22,85%	1,33 GeV	28,25%	1,32 GeV	28,11%
150 GeV	2,33 GeV	33,72%	2,37 GeV	34,18%	2,36 GeV	34,11%
180 GeV	3,29 GeV	38,69%	3,35 GeV	39,39%	3,34 GeV	39,35%
320 GeV	7,44 GeV	47,71%	7,36 GeV	47,24%	7,35 GeV	47,18%
350 GeV	8,56 GeV	51,36%	8,53 GeV	51,16%	8,59 GeV	51,54%

Tabela 4.6: Ganhos para quatro entradas e método de treinamento BFGS.

BFGS, foi constatada uma melhora tanto para o ganho relativo quanto para o ganho absoluto.

Quando comparamos os resultados obtidos para um estimador treinado com o algoritmo de primeira ordem com 4 entradas com os resultados obtidos com a mesma topologia treinada com o algoritmo de segunda, notamos uma melhora, como pode ser visto nas figuras 4.13 (ganho absoluto) e 4.14 (ganho relativo).




Figura 4.13: Ganho absoluto para um estimador com 4 entradas, diferentes energias e diferentes topologias.

Como foi observada uma melhora nos resultados, um novo conjunto de entradas foi utilizado para o treinamento dos estimadores. As entradas utilizadas




Figura 4.14: Ganho relativo para um estimador com 4 entradas, diferentes energias e diferentes topologias.

buscavam trazer uma maior quantidade de informação sobre a energia depositada nas camadas vizinhas à região sem leitura. Para isso, como variáveis de entradas, os quatro canais de energia com maior deposição das duas camadas vizinhas foram utilizados. Nas tabelas 4.7 e 4.8 estão expostos os resultados dos treinamentos de primeira e segunda ordem, respectivamente.

Energia	Topologia					
	10 - 2 - 1		10 - 12 - 1		10 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,53 GeV	28,65%	0,45 GeV	23,92%	0,54 GeV	28,81%
100 GeV	0,85 GeV	18,13%	0,90 GeV	19,18%	0,93 GeV	19,83%
150 GeV	1,91 GeV	27,53%	1,92 GeV	27,71%	1,82 GeV	26,29%
180 GeV	2,21 GeV	26,03%	2,65 GeV	31,18%	2,73 GeV	32,19%
320 GeV	6,31 GeV	40,51%	6,50 GeV	41,71%	5,89 GeV	37,77%
350 GeV	7,24 GeV	43,43%	7,02 GeV	42,11%	7,09 GeV	42,49%

Tabela 4.7: Ganhos para dez entradas e método de treinamento Steepest Descent.

Para os testes realizados com 10 entradas, utilizando o método de treinamento Steepest Descent foi constatada uma melhora com relação aos ganhos relativos com relação aos resultados obtidos para os estimadores com 4 entradas e treinamento de

primeira ordem.

Quando comparamos com os estimadores de 4 entradas e com o BFGS como algoritmo de treinamento, vemos que o estimador de 10 entradas obteve uma redução. Com esta comparação, fica claro que a inserção de 10 variáveis de entrada não se justifica, uma vez que com uma quantidade menor entradas e um algoritmo de treinamento mais efetivo encontramos um resultado melhor.

Com o algoritmo de segunda ordem, foi constatada uma melhora quando comparamos a resposta com as respostas dos estimadores treinados com o algoritmo de segunda ordem e duas entradas, embora a mesma seja pequena. Com isso, pode se dizer que a inserção de uma quantidade maior de informações pode não ser suficiente para a melhoria da resposta dos estimadores. Uma análise posterior pode ser desenvolvida para avaliar a relevância de cada uma das variáveis pertencentes ao conjunto de entrada testado.

Energia	Topologia					
	10 - 2 - 1		10 - 12 - 1		10 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,58 GeV	30,93%	0,59 GeV	31,73%	0,59 GeV	31,82%
100 GeV	1,35 GeV	28,58%	1,42 GeV	30,06%	1,41 GeV	29,94%
150 GeV	2,41 GeV	34,86%	2,44 GeV	35,22%	2,45 GeV	35,34%
180 GeV	3,38 GeV	39,78%	3,44 GeV	40,46%	3,43 GeV	40,42%
320 GeV	7,49 GeV	48,03%	7,49 GeV	48,05%	7,50 GeV	48,09%
350 GeV	7,86 GeV	47,10%	8,74 GeV	52,43%	8,70 GeV	52,20%

Tabela 4.8: Ganhos para dez entradas e método de treinamento BFGS.

Para concluir os testes com uma camada escondida, uma rede neural com 6 entradas, as duas energias das camadas vizinhas à região sem leitura, isto é, E_{LAr3} e E_{Tile1} , em conjunto com as energias de todas as outras camadas do sistema de calorimetria, isto é, E_{LAr2} , E_{LAr1} , E_{Tile2} e E_{Tile3} . Com isso toda a energia lida pelo sistema de calorimetria foi inserida na rede neural. Os resultados estão expressos na tabela 4.9, para o treinamento Steepest Descent e, na tabela 4.10, para o treinamento baseado em BFGS.

Com toda a energia que foi lida pelo sistema de calorimetria sendo inserida na rede neural, temos uma redução nos ganhos para as energias de 20, 100 e 150 GeV. Quando aumentamos a energia, este comportamento se inverte e para a energia

Energia	Topologia					
	6 - 2 - 1		6 - 12 - 1		6 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,36 GeV	19,27%	0,46 GeV	24,58%	0,50 GeV	27,67%
100 GeV	0,71 GeV	15,03%	0,45 GeV	9,65%	0,68 GeV	19,69%
150 GeV	1,21 GeV	17,46%	0,78 GeV	11,63%	1,79 GeV	26,55%
180 GeV	2,49 GeV	29,34%	2,71 GeV	31,95%	1,65 GeV	19,45%
320 GeV	5,32 GeV	34,14%	5,05 GeV	32,39%	4,95 GeV	31,78%
350 GeV	4,98 GeV	29,88%	5,36 GeV	32,15%	5,01 GeV	30,02%

Tabela 4.9: Ganhos para seis entradas e método de treinamento Steepest Descent.

de 180 GeV temos uma melhora nos resultados obtidos quando comparados com os estimadores neurais treinados com 10 entradas e o algoritmo Steepest Descent. Para as energia de 320 e 350 GeV, os resultados foram, novamente, inferiores se comparados aos resultados apresentados na tabela 4.8.

Avaliando estes resultados, podemos concluir que a utilização deste algoritmo não é eficiente para esta quantidade e formato de entradas.

Energia	Topologia					
	6 - 2 - 1		6 - 12 - 1		6 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,6 GeV	32,3%	0,7 GeV	37,56%	0,7 GeV	37,77%
100 GeV	1,59 GeV	33,63%	1,9 GeV	40,30%	1,93 GeV	41,01%
150 GeV	2,66 GeV	38,49%	3,26 GeV	47,06%	3,29 GeV	47,55%
180 GeV	3,63 GeV	42,73%	4,35 GeV	51,26%	4,33 GeV	51,02%
320 GeV	7,74 GeV	49,65%	9,17 GeV	58,85%	9,25 GeV	59,37%
350 GeV	8,73 GeV	52,32%	10,10 GeV	60,57%	10,22 GeV	61,28%

Tabela 4.10: Ganhos para seis entradas e método de treinamento BFGS.

Para os testes realizados com o algoritmo BFGS, observamos os melhores resultados para os estimadores com apenas uma camada escondida. A medida que aumentamos a quantidade de neurônios na camada escondidas, observamos também uma melhora, tanto para o caso de 2 para 12 neurônios quanto para o caso de 12 para 20 neurônios. Sendo que com 20 neurônios temos as melhores respostas para ganhos absolutos dos estimadores com apenas uma camada escondida.

4.4.2 Redes Neurais com duas camadas escondidas

Em trabalhos realizados anteriormente [6, 28], foi encontrada uma melhor resposta para estimação de energia com redes neurais que possuem 2 camadas escondidas. Este fato, foi a motivação necessária para os testes com redes neurais com duas camadas. E estes resultados serão expressos a seguir.

Os testes seguiram a mesma ordem dos testes de estimadores com uma camada escondida. Primeiramente iniciamos com uma quantidade menor de entradas e a partir daí fomos aumentando a quantidade de entradas a medida que os testes foram sendo realizados. Isto foi feito para buscar o melhor mapeamento possível para a energia depositada na região de materiais mortos.

No caso de duas camadas escondidas, a adição de neurônios nas camadas escondidas foi feita por tentativa e erro, tanto na primeira quanto na segunda.

Energia	Topologia					
	2 - 12 - 12 - 1		2 - 20 - 12 - 1		2 - 20 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,31 GeV	16,76%	0,32 GeV	16,91%	0,3 GeV	16,22%
100 GeV	0,42 GeV	8,81%	0,37 GeV	7,93%	0,37 GeV	7,87%
150 GeV	1,09 GeV	15,76%	1,15 GeV	16,63%	1,05 GeV	15,10%
180 GeV	1,99 GeV	23,37%	1,81 GeV	21,31%	1,88 GeV	22,16%
320 GeV	5,12 GeV	32,85%	5,11 GeV	32,80%	5,26 GeV	33,77%
350 GeV	5,97 GeV	35,78%	5,85 GeV	35,08%	6,01 GeV	36,05%

Tabela 4.11: Ganhos para redes neurais com duas entradas e duas camadas escondidas e utilizando o algoritmo Steepest Descent.

Ao analisarmos os resultados mostrados na tabela 4.11, podemos notar que as energias de 180, 320, 350 GeV, obtivemos uma melhora, no que concerne o ganho absoluto, se comparado aos resultados anteriores, isto é, as redes neurais implementadas com 6 entradas, apenas uma camada escondida e tendo o mesmo alvo, comportamento que é acompanhado também pelo ganho relativo. Já para baixas energias, isto é, 20, 100 e 150 GeV, temos uma leve redução, sendo que a maior queda é vista em 150 GeV, onde o ganho absoluto se reduz de 1,79 GeV, com uma rede neural que possui uma única camada escondida com 20 neurônios e 6 entradas, para 1,09 GeV, com rede com duas camadas escondidas, a primeira com 12 neurônios e a segunda com 12 neurônios, e apenas 2 entradas.

Comparativamente, quando analisamos apenas os resultados mostrados na tabela 4.11, notamos também que para todas as energias, quando modificamos a primeira camada escondida de 12 para 20 neurônios, obtivemos uma redução nos ganhos absolutos e relativos. Embora essa redução não seja encontrada quando modificamos as duas camadas em conjunto, ou seja, quando o terceiro conjunto de testes foi realizado. Quando as redes possuíam 20 neurônios na primeira e na segunda camadas escondidas, foi encontrada uma leve redução, para o ganho absoluto, para as energias de 100 e 150 GeV.

Concluídos os testes com o algoritmo de primeira ordem, os estimadores foram submetidos ao mesmo treinamento mas utilizando o algoritmo de segunda ordem, o BFGS. Os resultados dos 3 conjuntos de treinamento estão sendo expostos na tabela 4.12. Os resultados mostrados na tabela 4.12 mostram uma estabilidade quando analisamos o ganho absoluto. O ganho relativo, por sua vez, possui variações significantes para 50, 180 e 320 GeV.

Energia	Topologia					
	2 - 12 - 12 - 1		2 - 20 - 12 - 1		2 - 20 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,34 GeV	18,07%	0,34 GeV	18,05%	0,34 GeV	18,05%
100 GeV	0,67 GeV	14,32%	0,65 GeV	13,83%	0,65 GeV	13,86%
150 GeV	1,61 GeV	23,20%	1,60 GeV	23,10%	1,59 GeV	22,91%
180 GeV	2,56 GeV	30,15%	2,56 GeV	30,08%	2,57 GeV	30,29%
320 GeV	6,52 GeV	41,86%	6,52 GeV	41,85%	6,52 GeV	41,86%
350 GeV	7,63 GeV	46,73%	7,67 GeV	45,96%	7,63 GeV	45,75%

Tabela 4.12: Ganhos para redes neurais com duas entradas e duas camadas escondidas e utilizando o algoritmo BFGS.

Para estas 4 entradas, foram realizados 3 testes, no primeiro conjunto temos redes com 4 entradas, 12 neurônios na primeira camada escondida, 12 neurônios na segunda camada escondida e tendo como alvo a energia simulada para a região sem leitura. No segundo conjunto, temos redes com 4 entradas, 20 neurônios na primeira camada escondida, 12 neurônios na segunda camada escondida e o mesmo alvo dos conjuntos testados anteriormente. No terceiro conjunto, 6 redes neurais com 4 entradas, 20 neurônios na primeira camada escondida, 20 neurônios na segunda camada escondida e o mesmo alvo dos anteriores. Os resultados para estes três

conjuntos de testes estão expressos na tabela 4.13.

Energia	Topologia					
	4 - 12 - 12 - 1		4 - 20 - 12 - 1		4 - 20 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,49 GeV	26,15%	0,45 GeV	24,33%	0,51 GeV	27,47%
100 GeV	0,89 GeV	18,91%	0,92 GeV	19,42%	0,88 GeV	18,78%
150 GeV	1,85 GeV	26,78%	1,90 GeV	27,42%	2,03 GeV	29,37%
180 GeV	2,91 GeV	34,25%	2,65 GeV	31,25%	2,70 GeV	31,75%
320 GeV	6,12 GeV	39,29%	6,46 GeV	41,41%	6,29 GeV	40,32%
350 GeV	7,31 GeV	43,83%	7,24 GeV	43,42%	7,33 GeV	43,97%

Tabela 4.13: Ganhos para redes neurais com quatro entradas e duas camadas escondidas e utilizando o algoritmo Steepest Descent.

Com uma maior quantidade de informações sobre o sistema de calorimetria, as redes neurais apresentaram uma melhora significativa, quando analisamos o ganho absoluto. Para um feixe de píons de 150 GeV, obtivemos um ganho absoluto de 1,88 GeV para uma rede com 2 entradas e 20 neurônios nas duas camadas escondidas, enquanto que para uma rede com 4 entradas e 12 neurônios nas duas camadas escondidas encontramos um ganho absoluto de 2,91 GeV. Este resultado motiva a inserção de mais informações durante o treinamento das redes neurais.

Analisando os resultados mostrados na tabela 4.13, vemos uma estabilidade no ganho absoluto, para todas as energias, a medida que vamos adicionando neurônios as camadas escondidas, exceto por 150 GeV onde temos uma variação no ganho absoluto. Para o ganho relativo temos uma redução quando adicionamos neurônios na primeira camada escondida para energia de 150 GeV e temos um aumento quando adicionamos neurônios na primeira camada escondida para a energia de 180 GeV.

Uma vez que foram finalizados os testes com o algoritmo de primeira ordem, os procedimentos foram repetidos com o algoritmo de segunda ordem. A tabela 4.14 mostra os resultados destes testes. Podemos notar que obtivemos um ganho com relação ao ganho absoluto obtido com o método de treinamento Steepest Descent e também vemos um ganho com relação ao topologia anterior que utilizava o BFGS. Ainda com relação ao ganho absoluto temos uma estabilidade quando variamos a estrutura da rede neural, alterando a quantidade de neurônios nas duas camadas

escondidas, como mostrado na tabela 4.14.

Energia	Topologia					
	4 - 12 - 12 - 1		4 - 20 - 12 - 1		4 - 20 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,57 GeV	30,61%	0,57 GeV	30,54%	0,57 GeV	30,70%
100 GeV	1,38 GeV	29,34%	1,35 GeV	28,65%	1,35 GeV	28,75%
150 GeV	2,41 GeV	34,81%	2,40 GeV	34,67%	2,39 GeV	34,59%
180 GeV	3,35 GeV	39,41%	3,39 GeV	39,93%	3,38 GeV	39,73%
320 GeV	7,45 GeV	47,79%	7,53 GeV	48,29%	7,43 GeV	47,69%
350 GeV	8,69 GeV	52,10%	8,70 GeV	52,16%	8,73 GeV	52,34%

Tabela 4.14: Ganhos para redes neurais com quatro entradas e duas camadas escondidas e utilizando o algoritmo BFGS.

Como no caso das redes neurais com apenas uma camada escondida, o próximo conjunto de teste foi feito aumentando a quantidade de informações a respeito do sistema de calorimetria. Neste conjunto temos as 4 células de maior energia nas duas camadas vizinhas a região sem leitura e ainda temos as distribuições de energia das camadas vizinhas a região sem leitura.

Energia	Topologia					
	10 - 12 - 12 - 1		10 - 20 - 12 - 1		10 - 20 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,47 GeV	25,38%	0,54 GeV	29,13%	0,54 GeV	29,03%
100 GeV	0,98 GeV	20,88%	0,94 GeV	19,90%	0,99 GeV	20,92%
150 GeV	1,79 GeV	25,87%	1,77 GeV	25,62%	1,81 GeV	26,21%
180 GeV	2,73 GeV	32,19%	2,70 GeV	31,74%	2,88 GeV	33,96%
320 GeV	6,67 GeV	42,77%	6,52 GeV	41,84%	6,26 GeV	40,19%
350 GeV	7,21 GeV	43,25%	6,79 GeV	40,69%	7,05 GeV	42,30%

Tabela 4.15: Ganhos para redes neurais com dez entradas e duas camadas escondidas e utilizando o algoritmo Steepest Descent.

Na tabela 4.15 temos o resultado para as redes neurais com 10 entradas e o método de treinamento de primeira ordem. Com estes resultados vemos que para esta estrutura os resultados foram aproximadamente iguais aos resultados obtidos com os estimadores com apenas 4 entradas, ou seja, a adição de informações sobre as camadas vizinhas a região de materiais mortos não obteve uma melhora significativa.

Quando os testes foram implementados com o algoritmo BFGS, obtivemos uma resposta semelhante ao resultado obtido com as redes neurais com apenas 4 entradas, para o ganho absoluto. Embora o ganho relativo tenha mostrado um aumento quando alteramos o número de entradas e o número de neurônios na camada escondida. Os resultados deste conjunto de testes é mostrado na tabela 4.16.

Energia	Topologia					
	10 - 12 - 12 - 1		10 - 20 - 12 - 1		10 - 20 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,61 GeV	32,83%	0,61 GeV	32,77%	0,61 GeV	32,69%
100 GeV	1,46 GeV	31,00%	1,47 GeV	31,23%	1,47 GeV	31,29%
150 GeV	2,48 GeV	35,88%	2,49 GeV	35,91%	2,49 GeV	36,00%
180 GeV	3,49 GeV	41,07%	3,50 GeV	41,20%	3,49 GeV	41,09%
320 GeV	7,54 GeV	48,40%	7,61 GeV	48,81%	7,65 GeV	49,10%
350 GeV	8,83 GeV	52,95%	8,90 GeV	53,36%	8,82 GeV	52,88%

Tabela 4.16: Ganhos para redes neurais com dez entradas e duas camadas escondidas e utilizando o algoritmo BFGS.

O último conjunto de testes desenvolvido foi os estimadores com seis entradas, todas as informações lidas pelo sistema de calorimetria são inseridas nos estimadores. Estes estimadores foram treinados com os dois tipos de treinamento, o Steepest Descent e o BFGS. Os resultados estão sendo apresentados nas tabelas 4.17 e 4.18.

Energia	Topologia					
	6 - 12 - 12 - 1		6 - 20 - 12 - 1		6 - 20 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,57 GeV	30,33%	0,47 GeV	25,30%	0,43 GeV	23,00%
100 GeV	0,40 GeV	8,44%	0,91 GeV	19,28%	0,44 GeV	9,36%
150 GeV	0,56 GeV	8,12%	1,28 GeV	18,55%	0,99 GeV	14,33%
180 GeV	2,67 GeV	31,41%	2,33 GeV	27,47%	2,04 GeV	24,05%
320 GeV	5,71 GeV	36,60%	5,83 GeV	37,40%	4,73 GeV	30,32%
350 GeV	5,61 GeV	33,65%	6,06 GeV	36,31%	6,65 GeV	39,89%

Tabela 4.17: Ganhos para redes neurais com seis entradas e duas camadas escondidas e utilizando o algoritmo Steepest Descent.

Os resultados mostrados na tabela 4.17 apresentam uma redução no ganho absoluto quando comparado com as redes com 10 entradas, 20 neurônios na primeira camada escondida e 20 neurônios na segunda escondida. O mesmo comportamento

é observado no ganho relativo. Quando aumentamos o número de neurônios na primeira camada escondida, obtemos uma melhor resposta, sendo este comportamento seguido pelo ganho relativo.

Energia	Topologia					
	6 - 12 - 12 - 1		6 - 20 - 12 - 1		6 - 20 - 20 - 1	
	Ganho		Ganho		Ganho	
	Absoluto	Relativo	Absoluto	Relativo	Absoluto	Relativo
20 GeV	0,71 GeV	37,92%	0,71 GeV	38,12%	0,71 GeV	38,27%
100 GeV	1,92 GeV	41,17%	1,95 GeV	41,38%	1,96 GeV	41,54%
150 GeV	3,34 GeV	48,02%	3,32 GeV	47,96%	3,34 GeV	48,24%
180 GeV	4,46 GeV	52,46%	4,47 GeV	52,63%	4,45 GeV	52,32%
320 GeV	9,50 GeV	60,98%	9,45 GeV	60,63%	9,48 GeV	60,82%
350 GeV	10,45 GeV	62,65%	10,49 GeV	62,91%	10,44 GeV	62,62%

Tabela 4.18: Ganhos para redes neurais com seis entradas e duas camadas escondidas e utilizando o algoritmo BFGS.

Os resultados apresentados na tabela 4.18 apresentam uma melhora significativa em relação aos resultados apresentados nas tabelas 4.17 e 4.16. Sendo que também mostram uma estabilidade no ganho absoluto e no ganho relativo. Os resultados apresentados na tabela 4.18 são os melhores adquiridos durante os testes.

Capítulo 5

Conclusões

Neste projeto, foi desenvolvido um estimador neural de energia, que quando bem treinado, consegue com eficiência estimar a energia depositada em uma área sem leitura. No caso particular do sistema de calorimetria do detector ATLAS do LHC, onde este projeto foi desenvolvido, a informação sobre a energia que foi depositada nesta região é importante para a reconstrução da energia total depositada no sistema.

O projeto foi realizado em ROOT, o ambiente de análises disponibilizado pela colaboração CERN, que oferece um ambiente de fácil criação e treinamento de redes neurais. As análises foram desenvolvidas em C++ e os resultados extraídos através de uma interface criada especialmente para este propósito.

Os resultados mostram que o algoritmo de redes neurais obteve um melhor mapeamento que o modelo proposto pela colaboração CERN, no caso a média geométrica entre a energia depositada nas camadas mais próximas a região sem leitura. Outro resultado interessante é que com a adição de informações, obtivemos uma melhora nos ganhos absoluto e relativo, que foram as figuras de mérito utilizadas, o que comprova que o modelo que mapeia corretamente a energia nos materiais mortos vai além do modelo proposto.

Com isso, a estimação da energia para a região sem leitura do sistema de calorimetria obteve um ganho e com isso temos a motivação para a utilização da técnica de redes neurais artificiais no ambiente on-line da colaboração. Um projeto que também pode ser desenvolvido é a aplicação da estimação neural de energia como um todo no sistema de calorimetria, que seria a integração entre a estimação

neural da energia depositada no TileCal e a estimaco neural da energia depositada na regio de materiais mortos.

Referências Bibliográficas

- [1] NE'EMAN, Y., KIRSH, Y., *Particle Hunters*. 2 ed. Cambridge University Press, 1996.
- [2] “Processes Involving Charged Mesons”, *Nature*, v. 159, pp. 694–697, 1947.
- [3] LEE, J. V., *Searches for Higgs Bosons*. 1 ed. Nova Science Publishers, 2006.
- [4] “CERN - European Organization for Nuclear Research”, <http://www.cern.ch>, acessado em Outubro de 2009.
- [5] “LHC - The Large Hadron Collider”, <http://lhc.web.cern.ch>, acessado em Outubro de 2009.
- [6] SILVA, P. V. M. D., *Processamento de Sinais para Calibração, Teste e Estimativa de Energia com um Calorímetro Cintilante de Alta Velocidade*. Tese de doutorado, Universidade Federal do Rio de Janeiro, Julho 2007.
- [7] “ATLAS - A Toroidal Lhc AparatuS”, <http://atlas.web.cern.ch>, acessado em Outubro de 2009.
- [8] “CMS - Compact Muon Solenoid”, <http://cms.web.cern.ch>, acessado em Agosto de 2009.
- [9] “LHCb - Large Hadron Collider beauty”, <http://lhcb.web.cern.ch/>, acessado em Agosto de 2009.
- [10] “ALICE - A Large Ion Collider Experiment”, <http://aliceinfo.cern.ch>, acessado em Agosto de 2009.
- [11] “Inner Detector”, <https://twiki.cern.ch/twiki/bin/view/Atlas/InnerDetector>, acessado em Julho de 2009.

- [12] “Calorímetro Eletromagnético de Argônio Líquido”, <http://atlas.web.cern.ch/Atlas/GROUPS/LIQARGON/Organization/index.html>, acessado em Agosto de 2009.
- [13] “Calorímetro Hadrônico de Telhas Cintilantes”, <https://twiki.cern.ch/twiki/bin/view/Atlas/TileCal>, acessado em Outubro de 2009.
- [14] “Câmara de Muons”, <https://twiki.cern.ch/twiki/bin/view/Atlas/MuonSpectrometer>, acessado em Julho de 2009.
- [15] ATLAS Collaboration, “ATLAS Technical Design Report”, 1999, CERN/LHCC 99-14.
- [16] ATLAS Collaboration, ““ATLAS Inner Detector Technical Design Report””, 1997, CERN/LHCC 97-17.
- [17] ATLAS Muon Collaboration, “ATLAS Muon Spectrometer Technical Design Report”, 1997, CERN/LHCC 97-22.
- [18] WIGMANS, R., *Calorimetry: Energy Measurement in Particle Physics*. Clarendon Press, 2003.
- [19] F. ARIZTIZABAL, M. BOSMAN, M. C.-S., “Construction and performance of an iron-scintillator hadron calorimeter with longitudinal tile configuration”. In: *Nuclear Instruments and Methods in Physics Research*, pp. 384 – 397, 1994.
- [20] Tile Calorimeter Collaboration, “Tile Calorimeter Design Report”, 1996, CERN/LHCC 96-42.
- [21] K. Anderson, J. Pilcher, H. Sanders, F. Tang, “Front-end Electronics for the ATLAS Tile Calorimeter”. In: *4th Workshop on Electronics for the LHC Experiments*, 1998.
- [22] “TMS320C6414, Fixed-Point Digital Signal Processor, Texas Instruments”, <http://focus.ti.com/docs/prod/folders/print/tms320c6414.html>, acessado em Outubro de 2009.

- [23] HAYKIN, S., *Neural Networks. A Comprehensive Foundation*. 2 ed. Prentice-Hall, Inc., 1999.
- [24] YANLING ZHAO, BIMIN DENG, Z. W., “Analysis and study of perceptron to solve XOR problem”. In: *2nd International Workshop on Autonomous Decentralized System.*, pp. 168 – 173, 2002.
- [25] YUK DONGSUK, J. F., “Telephone speech recognition using neural networks and hidden Markov models”. In: *Proceedings of IEEE International Conference on Acoustics, Speech, and Signal Processing. ICASSP '99.*, pp. 157 – 160 Vol.1, 1999.
- [26] J. DAVID, REKHA KRISHNAN, A. K. S., “Neural Network Based Retinal Image Analysis”. In: *Congress on Image and Signal Processing, 2008. CISP '08.*, pp. 49 – 53 Vol.2, 2008.
- [27] Q.-H. MENG, W.-S. L., “A neural network adaptive control scheme for robot manipulators”. In: *Conference on Communications, Computers and Signal Processing, 1993.*, pp. 606 – 609 Vol.2, 1993.
- [28] BUDAGOV, YU A; KHUBUA, J. I. . K. Y. A. ., “Artificial Neural Networks for reconstruction of energy losses in dead materials between barrel LAr and Tile calorimeters : exploration and results”. In: *ATL-COM-TILECAL-2008-002*, 2006.
- [29] J. DAMGOV, L. L., “Application of neural networks for energy reconstruction”. In: *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, pp. 776 – 788, 2002.
- [30] Y.A. KULCHITSKY, M.V. KUZMIN, V. V., “Non-compensation of an Electromagnetic Compartment of a Combined Calorimeter”. In: *JINR-E1-99-303, JINR, Dubna, Russia*, 1999.
- [31] METROPOLIS, N., “The beginning of the Monte Carlo method”. In: *Special Issue dedicated to Stanislaw Ulam*, 1987.

- [32] J. ALLISON, K. AMAKO, J. A., “Geant4 developments and applications”. In: *IEEE Transactions on Nuclear Science*, pp. 270 – 278, 2006.
- [33] GOU-JEN WANG, J.-J. C., “Cascade steepest descent learning algorithm for multilayerfeedforward neural network”. In: *International Joint Conference on Neural Networks*, pp. 1889 – 1894 Vol.3, 1999.
- [34] V.S. ASIRVADAM, S.F. MCLOONE, G. I., “Memory efficient BFGS neural-network learning algorithms using MLP-network: a survey”. In: *Proceedings of the 2004 IEEE International Conference on Control Applications*, pp. 586 – 591 Vol.1, 2004.
- [35] M. HÖPPNER, D. W., “Applications of Neural Networks to Shower Analysis in Highly Segmented LAr Calorimeter”, *Nuclear Instruments and Methods*, v. A(389), pp. 154–156, 1997.

Apêndice A

Produção Bibliográfica

[1] MOURA JUNIOR, Natanael Nunes. ; SEIXAS, José Manoel; MAGACHO, Paulo Vitor, Estimativa Neural de Energia em Espaço Morto de um Calorímetro de Altas Energias. In: XXX Encontro Nacional de Física de Partículas e Campos - XXX ENFPC, 2009, Passa Quatro, MG. Programa e Resumos do XXX Encontro Nacional de Física de Partículas e Campos. São Paulo : Sociedade Brasileira de Física - SBF, 2009. p. 79-80. São Paulo : Sociedade Brasileira de Física - SBF, 2009.